



**Centro de Investigación en Materiales
Avanzados S.C.**

Desarrollo de un modelo neuronal para la predicción de las condiciones operacionales de un secador solar de productos agroindustriales

**TESIS QUE PARA OBTENER EL GRADO DE
MAESTRIA EN CIENCIA Y TECNOLOGÍA AMBIENTAL**

Presenta:
Dagoberto Rodríguez Ortiz

Director de tesis:
Dr. Erick César López Vidaña
Co-Directora de tesis:
Dra. Alma Yolanda Alanís García

AGRADECIMIENTOS

Deseo expresar mi más sincero agradecimiento a todas las personas que, de una u otra forma, contribuyeron a que este trabajo fuera posible.

En primer lugar, agradezco profundamente a mis asesores, el Dr. Erick y la Dra. Alma, por su invaluable guía, paciencia y apoyo a lo largo de este proceso. Su conocimiento y orientación fueron fundamentales para la realización de este trabajo.

A los miembros de mi comité, el Mtro. Jorge, el Dr. Ángel y el Dr. Ignacio, les agradezco por su tiempo, retroalimentación y consejos, los cuales enriquecieron significativamente mi investigación. Su compromiso y, sobre todo, su exigencia me motivaron a mejorar constantemente.

Extiendo mi gratitud a los investigadores y profesores del CIMAV que, con su disposición y conocimientos, me ayudaron a resolver dudas y me brindaron consejos que fortalecieron mi formación académica y profesional.

A mis compañeros y amigos, quienes compartieron conmigo momentos de estrés y alegrías, gracias por su apoyo, motivación y compañía en este camino.

Agradezco con todo mi corazón a mi familia, a mis padres y hermanos por su amor incondicional, paciencia y apoyo en cada etapa de este proceso. Su confianza en mí ha sido mi mayor fortaleza.

Y finalmente, a Dios por permitirme coincidir con todos ustedes.

A todos ustedes, gracias.

Resumen

Las redes neuronales han emergido como una técnica altamente efectiva para el modelado y control de sistemas tanto lineales como no lineales, lo que permite abordar una variedad significativa de problemáticas mediante una metodología unificada. En consecuencia, su popularidad ha experimentado un notable incremento debido al amplio espectro de aplicaciones en diversas áreas y especialidades. Es por esta razón que se considera su aplicación para el proceso de secado, que es un proceso unitario que conlleva la eliminación de agua mediante evaporación, produciendo un producto con contenido de humedad reducido. Este proceso puede ser afectado por la variabilidad de las condiciones climáticas, tal como se observa en el secador solar tipo túnel analizado en este trabajo. Por ello, en la presente investigación se han desarrollado dos modelos basados en redes neuronales de perceptrón multicapa (MLP, por sus siglas en inglés), diseñados para predecir las cinéticas de secado y los parámetros operacionales de una cámara de secado solar tipo túnel. Para este propósito, el modelo fue entrenado con datos recopilados a través de sensores ubicados dentro de la cámara de secado y bajo las condiciones ambientales externas. Realizando 14 experimentos para entrenar el modelo y obtener las cinéticas de secado de alimentos y el comportamiento térmico de la cámara. Tras el entrenamiento, el modelo fue validado para predicciones y sus hiperparámetros fueron optimizados para mejorar la precisión y la eficiencia, reduciendo errores. El modelo demostró una alta capacidad para generalizar y predecir con precisión las dinámicas del proceso, proporcionando una herramienta eficiente para la predicción de estas condiciones. Permitiendo la modificación de estrategias en función de las condiciones futuras proyectadas, otorgando una ventaja competitiva y asegurando una mayor eficiencia y sostenibilidad.

ÍNDICE GENERAL

1. Introducción	10
1.1. Antecedentes	12
1.2. Justificación	16
1.3. Hipótesis	18
1.4. Objetivos	19
1.4.1. Objetivo general	19
1.4.2. Objetivos específicos	19
2. Secado Solar	20
2.1. Generalidades del Secado	21
2.2. Secado solar	21
2.2.1. Secado solar tradicional	22
2.2.2. Secado solar tecnificado	22

2.2.3. Clasificación del secado solar	22
2.2.4. Secadores del tipo convección natural	24
2.2.5. Secadores del tipo convección forzada	24
2.2.6. Secadores solares híbridos	25
2.3. Contenido de humedad	26
2.3.1. Base Húmeda	26
2.3.2. Base seca	27
2.3.3. Curvas de secado	28
3. Redes neuronales artificiales	30
3.1. Concepto de una RNA	30
3.1.1. Arquitectura de redes neuronales	31
3.1.2. Diseño de una red neuronal	32
3.1.3. Proceso de aprendizaje	32
3.2. El perceptrón	34
3.3. El perceptrón multicapa	35
3.3.1. Aprendizaje por lotes	36
3.3.2. Aprendizaje en línea	37
3.3.3. Generalización	37
3.4. Algoritmos Bio-Inspirados	38
3.4.1. Algoritmos Genéticos	38
3.4.2. Optimización de enjambre de partículas	40

3.4.3. Colonias de abejas artificiales	41
3.5. Algoritmos evolutivos para el entrenamiento de redes neuronales	42
3.5.1. Elección de los pesos iniciales	43
3.5.2. Elección de la arquitectura de la red	43
3.5.3. Evolución de la regla de aprendizaje	43
3.6. El control en el proceso de secado	44
3.7. Control inteligente	45
4. Metodología	47
4.1. Materiales	47
4.1.1. Descripción de la cámara de secado	48
4.1.2. Productos a secar	48
4.1.3. Adquisidor de datos	49
4.2. Métodos	54
4.2.1. Diseño de la arquitectura para una RNA	54
4.2.2. EV del rendimiento de la RNA	55
4.2.3. Análisis paramétrico	56
4.2.4. Algoritmo Genético	57
5. Resultados	59
5.1. Datos de secado	59
5.2. Elección de la arquitectura	62

5.2.1. Análisis paramétrico	62
5.2.2. Algoritmo evolutivo	63
5.3. Evaluación del rendimiento	71
5.3.1. Desempeño del modelo RNA 1 en pruebas experimentales	71
5.3.2. Desempeño del modelo RNA 2 en pruebas experimentales	77
6. Conclusiones	82
6.1. Trabajo Futuro	83
6.2. Lista de publicaciones	83

ÍNDICE DE FIGURAS

2.1.	Clasificación de secadores solares según Patil y Gawande [43]	23
2.2.	Clasificación de secadores solares según Ekechukwu y Norton [11].	23
2.3.	Secador solar de convección natural [45]	24
2.4.	Secador solar de convección forzada [11, 45]	25
2.5.	Secador solar híbrido	25
2.6.	Analizador de humedad	28
2.7.	Curvas de velocidad de secado [44]	29
3.1.	Modelo de una neurona artificial [51].	31
3.2.	Representación de un perceptrón Fuente: [51].	34
3.3.	Modelo de una red neuronal del tipo perceptrón multicapa [49].	36
3.4.	Representación de un AG tradicional [57].	38
3.5.	Representación de un ABC	42

3.6. Estructura de un sistema de control centrada en la calidad del producto.	44
4.1. Secador solar tipo túnel	48
4.2. Cámara de secado	48
4.3. Distribución de los sensores dentro de la cámara de secado	50
4.4. Sistema de adquisición de datos	50
4.5. Sensor Sensirion SHT4X	51
4.6. Galga extensiométrica de 5Kg	52
4.7. piranómetro CMP6	52
4.8. Página web alojada en los servidores del CIMAV (link)	53
4.9. Diagrama de flujo del algoritmo evolutivo para selección de arquitectura	58
5.1. Cinéticas de secado derivadas del proceso de deshidratación de los alimentos . .	61
5.2. Entrenamientos mediante el análisis paramétrico	62
5.3. Entrenamiento mediante AG RNA 1	64
5.4. R^2 para RNA 1	65
5.5. Histograma	66
5.6. Arquitectura RNA 1	66
5.7. Entrenamiento mediante AG RNA 2	67
5.8. Analisis de sensibilidad para RNA 2	68
5.9. R^2 para RNA 2	69
5.10. Histograma RNA 2	70

5.11. Arquitectura RNA 2	70
5.12. Condiciones ambientales experimento 1	72
5.13. Temperaturas dentro de la cámara de secado experimento 1	73
5.14. Humedad relativa dentro de la cámara de secado experimento 1	74
5.15. Condiciones ambientales experimento 2	75
5.16. Temperaturas dentro de la cámara de secado experimento 2	76
5.17. Humedad relativa dentro de la cámara de secado experimento 2	77
5.18. Condiciones ambientales experimento 3	78
5.19. Cinéticas de secado experimento 3	79
5.20. Condiciones ambientales experimento 3	80
5.21. Cinéticas de secado experimento 4	81

ÍNDICE DE TABLAS

2.1. Ventajas y desventajas de los diferentes tipos de secadores solares [46]	26
3.1. Comparativa aprendizaje automático y termodinámica tradicional [64]	45
3.2. Comparativa control tradicional y control inteligente	46
4.1. Componentes secador solar tipo tunel	47
4.2. Productos seleccionados para obtención de datos experimentales	49
4.3. Especificaciones SHT40I-AD1F [67]	51
4.4. Características galga extensiométrica [69]	52
4.5. Características piranómetro CMP6 [71]	53
4.6. Entradas y salidas del modelo neuronal	54
4.7. Selección de función de entrenamiento	57
4.8. Funciones de entrenamiento MATLAB [80]	57

5.1. Alimentos deshidratados	60
5.2. Configuración para el análisis paramétrico	62
5.3. Configuración para el algoritmo evolutivo	63
5.4. Entradas RNA 2	68
5.5. Experimentos realizados	71
5.6. Condiciones experimento 1	72
5.7. Parámetros evaluados experimento 1	73
5.8. Condiciones experimento 2	74
5.9. Parámetros evaluados experimento 2	75
5.10. Condiciones experimento 3	77
5.11. Parámetros evaluados experimento 3	78
5.12. Condiciones experimento 4	80
5.13. Parámetros evaluados experimento 4	80

CAPÍTULO 1

INTRODUCCIÓN

Los países miembros de la ONU (Organización de las Naciones Unidas) en el 2015 aprobaron el mayor plan de acción global para un mundo más inclusivo y próspero llamado agenda 2030, el cual consiste en 169 metas que deberán ser cumplidas para el año 2030, dichas metas se pueden resumir en 17 objetivos los cuales son llamados “Objetivos de Desarrollo Sostenible” (ODS), mismos que buscan eliminar la pobreza, salvaguardar el planeta y garantizar la prosperidad para todos los seres vivos de la tierra, cada meta posee objetivos concretos [1]. Dentro de los 17 objetivos se abarca una amplia gama de temas, desde la erradicación de la pobreza hasta la lucha contra el cambio climático [2]. Los objetivos relevantes para el desarrollo de esta investigación son el objetivo número 2 “Hambre Cero” el cual tiene como meta establecer un mundo sin hambre para el 2030, debido a la problemática mundial del hambre y la inseguridad alimentaria, la cual ha tenido un incremento preocupante desde el 2015, intensificada por una mezcla de elementos como las disputas, el cambio climático y la intensificación de las desigualdades [2] y el objetivo número 7 “Energía Asequible y no contaminante”, que aspira a asegurar el acceso a una energía limpia y accesible, esencial para el progreso de la agricultura, las compañías, las comunicaciones, la educación, la salud y el transporte [1].

Sin embargo, la pérdida y desperdicio de alimentos no es únicamente una inquietud social

o humanitaria, sino también ambiental. Al desechar alimentos, también se desperdicia toda la energía y agua necesaria para su cultivo, recolección, transporte y empaquetado. De acuerdo con información reciente, el despilfarro y la pérdida alimentaria generaron entre el 8 % y el 10 % de las emisiones globales de gases de efecto invernadero (GEI) y una significativa disminución de la biodiversidad al tomar casi un tercio de las tierras agrícolas a nivel global, representando un gasto cercano a 1 billón de dólares [3]. Adicional a esto, en todo el mundo se desperdicia aproximadamente un 31 % de los alimentos, del cual, aproximadamente el 14 % [4] de los alimentos, valorados en alrededor de 400,000 millones de USD, se desperdicia entre la recolección y la distribución, mientras que el 17 % [4] se pierde durante su distribución y en manos de los consumidores finales.

Una manera de disminuir la pérdida y desperdicio de alimentos es mediante la preservación y conservación de alimentos, esto ayuda a minimizar el derroche y garantizar un uso más eficaz de los recursos, entre los métodos de conservación más destacados se incluyen: la conservación en frío, que inhibe los agentes alterantes (algunos de manera total y otros de forma parcial), lo que facilita la preservación de alimentos a largo plazo y el tratamiento térmico, cuyo objetivo es neutralizar o aniquilar los agentes patógenos [5]. Dentro de los tratamientos térmicos se encuentra el secado, el cual se emplea principalmente para conservar los alimentos, sin embargo, demanda grandes volúmenes de energía que constituyen entre el 10 % y el 15 % del consumo total de energía en la industria [6]. Así mismo, el elevado precio de los combustibles fósiles y la creciente inquietud por el efecto de estos en el medio ambiente, hacen que la implementación de energías renovables sea una opción sustentable.

Estas fuentes de energía verde no solo contribuyen a disminuir los GEI (Gases de Efecto Invernadero), sino que además fomentan la autonomía energética y disminuyen la contaminación, aportando al séptimo objetivo “energía asequible y no contaminante” de los objetivos de desarrollo sostenible [1]. Para esto se tiene el secado solar, una alternativa sustentable para la conservación de alimentos, el cual utiliza la energía solar para deshidratar alimentos, disminuyendo el contenido de humedad y previniendo así su rápido deterioro. Esta práctica no solo disminuye las pérdidas después de la cosecha, sino que también posibilita el uso de excedentes de producción, reduciendo el desperdicio y creando alternativas saludables y prolongadas para el consumo humano.

La implementación de energías renovables demanda el uso de sistemas de control sofisticados para asegurar su eficiencia y estabilidad [7]. Los sistemas de control facilitan la gestión en tiempo real de la generación y distribución, mejorando el flujo de energía, de esta forma la fusión de energías renovables y tecnología de control no solo disminuye la necesidad de combustibles fósiles, sino que también promueve una transición hacia un sistema energético

más sustentable y resiliente. El progreso de la ingeniería y la ciencia ha sido impulsado en gran medida por el desarrollo y la implementación de sistemas de control automático y modelos predictivos. Estos sistemas han revolucionado diversas industrias y sectores, desde la tecnología aeroespacial hasta los procesos de diseño, fabricación y las operaciones industriales. El control automático se ha convertido en un aspecto esencial de cualquier sistema que requiera la regulación de una variable, garantizando su funcionamiento eficiente y eficaz [8]. De la misma manera, el constante progreso en la inteligencia artificial (IA) y su adopción creciente en múltiples áreas, como las energías renovables, permite tener sistemas eficaces, sostenibles y resilientes [9].

1.1. Antecedentes

La energía solar, parte de las energías renovables, se ha empleado durante muchos años para el proceso de secado, permitiendo así la preservación de frutas y vegetales, cereales y otros productos de la agricultura. El secado es uno de los métodos más antiguos empleados para la agricultura y el almacenamiento de alimentos, el cual ha sido utilizado desde los inicios de la humanidad, dado que ofrece al ser humano una oportunidad de supervivencia en períodos de escasez de alimentos, momentos en los que el secado les permite tener reservas de alimentos, lo que permite la supervivencia [10]. El proceso de secado se caracteriza por la transferencia simultánea de calor y masa [11], lo que resulta en la reducción de la humedad en los alimentos, minimizando el desarrollo de microorganismos, así como el deterioro bioquímico y químico [12], procesos que causan un deterioro en el alimento o producto. Además, su volumen y peso son disminuidos, lo que se traduce en una reducción de los costos de empaquetado y transporte. Asimismo, el almacenamiento puede llevarse a cabo a temperatura ambiente durante largos períodos [11], reduciendo el costo de almacenamiento en comparación con alimentos que requieren refrigeración para su conservación, lo cual consume energía y representa un gasto.

Los métodos utilizados para el secado comenzaron con el tradicional secado a cielo abierto, en el cual el producto se distribuye sobre el suelo, ya sea de tierra, cemento, piso, techo o cualquier superficie plana que esté expuesta a la radiación solar y a las corrientes de aire naturales [13]. Este método presenta varias desventajas como la contaminación con polvo, la interacción con insectos o animales del entorno, la limitada capacidad de control sobre el proceso y la dependencia total de las condiciones climáticas. No obstante, con el avance de la tecnología, estos métodos se han ido tecnificando, mejorando el proceso y la eficiencia del secado. Dichos avances van desde la mejora del proceso hasta el diseño de sistemas complejos de secado, como lo son los secadores solares que incorporan materiales de cambio de fase

(PCM), los cuales se distinguen por su eficiencia superior y la reducción del tiempo requerido para el secado de las cosechas [14]. Sin embargo, estos sistemas complejos utilizan sistemas de instrumentación y control que en su mayoría funcionan con sistemas de control tradicionales [7], ignorando el avance en los sistemas de control e instrumentación. Sin embargo, existe poca literatura en la cual se implementan algunas técnicas modernas de control e instrumentación, considerando el uso de inteligencia artificial como la novedad, a pesar de que esta se empezó a desarrollar desde 1943 cuando Warren McCulloch y Walter Pitts desarrollaron el primer modelo matemático para una red neuronal [15], siendo John McCarthy el que bautiza a esta disciplina con el término “Inteligencia Artificial” en la conferencia de Dartmouth en 1956 [16], dando inicio oficial al desarrollo de esta.

La inteligencia artificial permite optimizar procesos y predecir comportamientos, como el trabajo de Morales D. y colaboradores en el cual mediante una red neuronal artificial predicen la radiación solar [17] mostrando un desempeño aceptable en la predicción de esta variable, mientras que J.A. Hernández y colaboradores utilizaron una red neuronal para la predicción de transferencia de calor y masa durante el secado de yuca y mango [18]. Las redes neuronales se han empleado con éxito en diversos problemas de predicción, gracias a su habilidad para modelar y anticipar series de tiempo no lineales con gran precisión, detectar cualquier tipo de relación entre los datos sin requerir conocimiento previo del problema que se esté modelando [19]. Siendo la acertada predicción un instrumento esencial para llevar a cabo una adecuada planificación y diseño en sistemas de secado.

En el caso de los sistemas de secado tecnificados se presentan dos problemas principales: por el lado de diseño no se tiene una herramienta que pueda predecir o simular las condiciones de un secador y, por el lado de control, el cual en cierto tipo de alimentos como los probióticos [20], se debe tener un control preciso debido a la sensibilidad del calor de ese tipo de biomateriales. Sin embargo, alimentos como las frutas y verduras frescas, alimentos ricos en antioxidantes, pueden perder rápidamente su frescura, textura, color y valor nutricional si el proceso de secado no es el adecuado [21]. El método de secado por convección implica soplar aire caliente sobre el alimento para eliminar la humedad. Si bien se utiliza ampliamente, puede provocar una degradación de la calidad si no se controla la temperatura con precisión [21]. Para los sistemas de secado que dependen de la energía eléctrica, como el secado por infrarrojos o el secado por microondas, se utilizan sistemas de control ON/OFF o Proporcional-Integral-Derivativo (PID) [7]. Esto se debe a la linealidad inherente del proceso, un sistema se considera lineal cuando se cumplen con los siguientes principios [8]:

- Superposición: la cual nos dice que la respuesta obtenida a partir de una combinación lineal de entradas sea equivalente a la combinación lineal de las respuestas correspon-

dientes individuales, por ejemplo para un sistema con entradas u_1 y u_2 y salidas y tenemos $y(u_1 + u_2) = y(u_1) + y(u_2)$

- Homogeneidad: La respuesta del sistema a una entrada escalada es proporcional al mismo escalamiento por ejemplo $Cu_1 = Cy$ donde C es una constante

El cumplir con estos dos principios implica que la relación entre entrada y salida puede ser descrita a través de ecuaciones diferenciales lineales o funciones de transferencia. Sin embargo, si alguno de los principios no se cumple, nuestro sistema es un sistema no lineal, en el cual las relaciones entrada-salida son más complejas, más difíciles de analizar y controlar. Además, los sistemas reales frecuentemente se apartan de estas suposiciones lineales, puesto que los modelos matemáticos, por lo general, no contemplan sensores, actuadores y perturbaciones externas, los cuales introducen complejidades y no linealidades inherentes al funcionamiento normal del propio sistema.

En el caso del proceso del secado solar es considerado como no lineal. Esto se debe a que la tasa de secado no es constante y puede variar en función de múltiples factores, como la temperatura, la humedad relativa del aire, la velocidad del aire y las características del producto que se está secando [22], si se implementa un control lineal a un proceso no lineal como un PID puede provocar fallas en estos sistemas, dado que el PID se basa en modelos lineales, por lo que no maneja bien estas dinámicas complejas y no lineales [23], por lo que se abren oportunidades a modelos de control basados en la inteligencia artificial, mismos modelos que pueden predecir y controlar las variables de un sistema lineal o no lineal, aún bajo condiciones de operación inciertas.

Los sistemas de control son cruciales en muchos ámbitos. Sin embargo, existen diferencias fundamentales entre el enfoque clásico (diseño basado en teoría bien establecida) y el uso de redes neuronales. Estas diferencias son descritas por P.L. de Vaal [24] el cual establece como una de las principales distinciones la estructura del problema de control, para los sistemas complejos o poco conocidos, en los que el modelado matemático es complejo o no se puede obtener del todo, se considera que el enfoque de control clásico puede no ser el más eficaz, debido a que se basa en modelos matemáticos físicos o explícitos, mientras que las redes neuronales aprenden del comportamiento del sistema, incluso en ausencia del modelo físico. Haciendo que puedan desempeñar un papel crucial tanto para el control como para la predicción en sistemas donde tener un modelo matemático del sistema es complejo. Aprovechando estas capacidades de las redes neuronales, es posible abordar problemas de control demasiado complejos para los métodos clásicos. Las redes neuronales pueden aprender de los datos y adaptarse a entornos cambiantes, lo que las convierte en una herramienta flexible y potente para las aplicaciones de control. A diferencia de los modelos matemáticos tradicionales, que

requieren una comprensión precisa de las relaciones subyacentes entre las variables, las redes neuronales pueden aprender de los ejemplos y adaptarse a nuevas situaciones, lo que posibilita su implementación en diversas aplicaciones vinculadas al ámbito del control.

El estudio realizado por Farhat Mahmood [25] es un ejemplo de lo dicho anteriormente de cómo se ha aplicado un sólido marco de control predictivo de modelos (MPC) basado en un modelo de red neuronal (RNA) en un invernadero para mejorar la gestión de la temperatura y la energía. Al hacer la comparativa de un modelo RNA con el modelo analítico, las comparaciones demostraron que la RNA superó al modelo analítico, logrando errores de consigna de temperatura (RMSE) más bajos de 0.32 °C en invierno y 0.60 °C en verano. Además, resultó en una reducción del consumo de energía por debajo del 9.67 % en invierno y 23.61 % en verano, lo que evidencia una mejora en la gestión de la temperatura y la energía en condiciones inciertas [26].

Una investigación adicional desarrollada por Zehui Jia [27] se enfocó en mejorar tanto el color como la cinética de secado de las rodajas de manzana al optimizar el proceso de secado con aire caliente utilizando técnicas de aprendizaje automático y profundo. Se analizaron distintos tiempos y temperaturas de secado, así como métodos para controlar la humedad, logrando así un secado más eficiente y una calidad de color superior. Los modelos, que abarcaron desde redes de retropropagación (BP) hasta redes neuronales convolucionales CNN-LSTM, redes convolucionales temporales (TCN) y redes de memoria a corto-largo plazo (LSTM), predijeron con precisión el contenido de humedad y las variaciones de color en las rodajas de manzana. Destacaron las redes LSTM por su sobresaliente capacidad predictiva, con un coeficiente de determinación (R^2) mayor a 0.98, lo que evidencia una alta exactitud [27].

El trabajo realizado por Francik Sławomir [28], desarrolló cuatro modelos llamados RNA1, RNA2, RNA3 y RNA4 para la cinética del secado de cebolla mediante el uso de redes neuronales artificiales (RNA), considerando el pretratamiento previo al secado y varios niveles de temperatura. Se utilizó el contenido de humedad del material seco en un momento dado como variable dependiente (salida de la RNA). Las variables independientes (entradas de la RNA) incluyeron la temperatura de secado, el grosor inicial de la muestra, el contenido inicial de humedad, la masa inicial de la muestra, el tiempo de secado y el pretratamiento del material. El modelo general RNA1 incorpora todas las variables de entrada, mientras que los otros tres se enfocan en tipos individuales de pretratamiento. En el modelo más eficaz (RNA1), los valores del error absoluto medio porcentual (MAPE) oscilaron entre un 5.88 % y un 7.02 % en distintos conjuntos de datos: entrenamiento, prueba y validación [28].

La investigación realizada por Muhammed Emi Topal [29] analiza la cinética del secado

de *Citrus medica* a través del empleo de liofilización bajo diversas condiciones de espesor y presión dentro de la cámara. Adicionalmente, se evaluó la eficacia de una red neuronal artificial (RNA) en la predicción de parámetros cruciales tales como la relación de humedad (MR), el contenido de humedad y la velocidad de secado. Para modelar el proceso de liofilización del *Citrus medica*, se implementó una arquitectura de red neuronal del tipo perceptrón multicapa (MLP) con retroalimentación. La RNA fue entrenada utilizando un conjunto de datos que incluyó varias condiciones de secado y características del producto, y su rendimiento fue evaluado mediante métricas robustas como el error cuadrático medio (RMSE) y el coeficiente de determinación R^2 . Al contrastar el MR obtenido experimentalmente con el MR estimado por el modelo de RNA bajo diferentes espesores del producto y presiones de cabina, se encontró que el R^2 alcanzó 0.998 y el RMSE fue de 0.010574. A través del uso de datos experimentales en modelos matemáticos y en una red neuronal artificial, se establecieron las condiciones óptimas del proceso. Los resultados de este estudio sugieren que las redes neuronales artificiales son potencialmente aplicables para describir el proceso de liofilización de *Citrus medica* [29].

En el estudio desarrollado por Halil Nusret Bulus [30], llevó a cabo un proceso de secado por microondas con el propósito de reducir el tiempo, la energía y el costo asociados a los procedimientos de secado. Para ello, se implementaron dos métodos de predicción basados en aprendizaje automático: la Red Neuronal Artificial (RNA) y el Sistema de Inferencia Neurodifusa Adaptativa (ANFIS), con el objetivo de modelar la eliminación de residuos. Los enfoques RNA y ANFIS fueron aplicados a un conjunto de datos derivados del cálculo del contenido de humedad y de los valores de la tasa de secado. Se evidenció que los modelos ANFIS y RNA resultan adecuados para predecir los niveles de humedad; sin embargo, no son eficaces para la predicción de las tasas de secado [30].

1.2. Justificación

El proceso de secado es una operación unitaria intensiva en el consumo de energía, el proceso de secado utiliza entre el 10 % y 15 % del consumo total de energía de la industria, entre 5.94 GWh y 8.91 GWh [6, 31], normalmente esta energía es suministrada por combustibles fósiles, lo cual genera altos costos de producción y un impacto ambiental negativo. El secado es ampliamente empleado en la conservación de productos alimenticios y farmacéuticos. Su objetivo consiste en eliminar la humedad de los alimentos, lo que inhibe el crecimiento de microorganismos y bacterias que pueden causar su deterioro e intoxicación alimentaria [32]. Como resultado, los alimentos pueden almacenarse durante varios meses con la calidad adecuada para ser consumidos.

En países en vías de desarrollo normalmente se aplica el secado solar a cielo abierto, lo cual tiene diversas desventajas inherentes al mismo proceso, como contaminación por polvo, roedores, aves, lluvia, etc. Por lo que es necesario el uso de estructuras que protejan el alimento de la intemperie. Con el propósito de mitigar o eliminar las desventajas asociadas al secado solar directo o tradicional, se ha avanzado en su tecnificación. Esto implica el uso de sistemas mejorados para el secado de productos, empleando la energía solar de manera más eficiente y controlada en relación con los métodos tradicionales de secado al sol, métodos que han sido objeto de estudio durante varios años, tal como se evidencia en el trabajo de H. R. Bolin y colaboradores (1982), en el cual se enfatiza el papel fundamental de la tecnificación del proceso de secado, mediante la implementación de tecnologías como secadores con colectores solares [33]. Sin embargo, debido a la intermitencia de las condiciones climatológicas, el suministro energético no es constante, lo que puede afectar la uniformidad de la calidad de los productos secos [34]. Esta situación hace cada vez más necesario tener un control de las variables operacionales. El control de la temperatura y humedad relativa es uno de los desafíos más importantes a los que se enfrentan los fabricantes de secadores solares y del cual depende principalmente su desempeño, consumo energético y la calidad del producto final. En la actualidad, los sistemas de control disponibles para regular la temperatura o la humedad relativa del aire en secadores solares de productos agroindustriales no ofrecen una solución integral. Esto se debe a que estos sistemas se centran exclusivamente en controlar una de estas dos variables, ya sea la temperatura o la humedad, pero no ambas simultáneamente y, al mismo tiempo, los secadores con algún control suelen estar equipados con un control convencional ON-OFF que tiene como consecuencia que los secadores sean ineficientes y con un consumo energético mayor, ya que el rango de variación de la temperatura o humedad se vuelve demasiado grande [35].

De la misma manera, la simulación de sistemas de secado utilizando técnicas como la dinámica de fluidos computacional (CFD) normalmente se enfoca en, como su nombre lo dice, en el flujo de los fluidos, transferencia de calor y masa [36] lo cual implica modelar y representar varios procesos termodinámicos y matemáticos, los cuales presentan una alta complejidad algorítmica, demandan una gran cantidad de recursos computacionales y conllevan un largo tiempo de desarrollo. De la misma manera, la predicción es un instrumento crucial en diversas áreas, ya que facilita la anticipación de resultados y la toma de decisiones fundamentadas antes de llevar a cabo aplicaciones en el mundo real.

En campos como la ingeniería, la economía, la medicina y la administración del medio ambiente, la predicción contribuye a prevenir errores, mejorar la eficiencia de diversos elementos y reducir los efectos adversos. Adicionalmente, estos métodos simplifican la planificación a largo plazo, dado que posibilitan la modificación de estrategias en base a las condiciones futu-

ras proyectadas, otorgando una superioridad competitiva y asegurando una mayor eficiencia y sostenibilidad [37]. Sin embargo, utilizando técnicas de inteligencia artificial se puede desarrollar un modelo predictivo sobre el comportamiento de un sistema de secado solar a partir del entrenamiento de una red neuronal artificial (RNA). Este modelo, al estar basado en datos toma en consideración múltiples variables de entrada, tales como la temperatura, la humedad relativa y la irradiancia solar. La gestión y optimización de estas variables se lleva a cabo mediante la aplicación de redes neuronales, logrando predecir la temperatura, así como la humedad relativa y la pérdida de peso en función del tiempo de ciertos alimentos. Al incorporar estos factores al algoritmo, el sistema puede optimizar el proceso de secado para obtener productos de alta calidad, obteniendo una mejor eficiencia energética [38] y una mejor planificación y toma de decisiones. Al prever el rendimiento del sistema bajo diferentes condiciones climáticas [39], al mismo tiempo, el modelo neuronal puede ser utilizado para la puesta en marcha de un sistema de control, reemplazando sistemas de control ya existentes mediante un controlador discreto, modelo inverso o un control híbrido, esto debido a la simplicidad inherente en el diseño de una red neuronal, la cual, una vez entrenada, su implementación puede resultar más sencilla en comparación con el desarrollo de modelos matemáticos complejos los cuales son utilizados para el desarrollo de un sistema de control, lo que permite un ahorro tanto de tiempo como de recursos computacionales [38].

De manera análoga, contar con un sistema capaz de predecir el comportamiento de la cámara de secado contribuye significativamente a la optimización del proceso, esto a raíz de identificar las condiciones óptimas de secado, como la temperatura y el tiempo de secado, incrementando la eficiencia del proceso, reduciendo el gasto energético y maximizando la calidad del producto final. Esto adquiere particular relevancia en la industria alimentaria, donde la calidad del producto constituye un aspecto fundamental. Comprender el comportamiento de una cámara de secado a lo largo del tiempo, o su desempeño bajo determinadas cargas, conlleva un proceso más eficiente, ya que minimiza las pérdidas relacionadas con productos mal secados o desperdicio de alimentos, reduciendo los costos de experimentación y mejorando la planificación del proceso de secado.

1.3. Hipótesis

El desarrollo de un sistema basado en redes neuronales artificiales entrenado con datos experimentales del secado de diversos productos, permitirá predecir la temperatura y la humedad relativa dentro de la cámara de secado, así como la cinética de secado de productos alimenticios.

1.4. Objetivos

1.4.1. Objetivo general

Desarrollar un modelo predictivo basado en redes neuronales que posea la capacidad de predecir tanto la temperatura como la humedad relativa dentro de una cámara de secado, además de predecir la cinética de secado de alimentos en un secador solar de productos agro-industriales.

1.4.2. Objetivos específicos

1. Desarrollar una base de datos experimental de secado solar de productos alimenticios.
2. Desarrollar y optimizar un modelo de red neuronal para predecir las variables de temperatura, humedad relativa así como la cinética de secado.
3. Evaluación, mediante pruebas experimentales, del rendimiento de la red neuronal desarrollada utilizando los indicadores R^2 , $RMSE$ y $MAPE$.

CAPÍTULO 2

SECADO SOLAR

El secado es un proceso en el que intervienen los mecanismos de transferencia de calor y transferencia de masa, para eliminar la humedad de los alimentos, lo que permite la inhibición del crecimiento de microorganismos y bacterias que pueden causar su deterioro e intoxicación alimentaria [32]. Siendo en la industria alimentaria uno de los métodos de conservación más populares para frutas, verduras y otro tipo de alimentos. La palabra “conservación” se refiere al proceso de prolongar la vida útil de un producto con una calidad deseada. Secar alimentos agrega un valor al producto, variando los valores nutricionales y aumentando su tiempo de anaquel [11]. Para esto es necesaria la aplicación de calor o energía para lograr secar algo, la energía necesaria para esto es un gran problema en el secado y en general para la industria, actualmente la comunidad mundial depende en gran medida de los combustibles fósiles, siendo estos no renovables y generadores de gases de efecto invernadero, por motivos como estos se busca una fuente de energía alternativa como lo es la energía solar.

2.1. Generalidades del Secado

El secado es un método esencial para preservar los alimentos y tal vez el más antiguo. Se refiere a la acción que contribuye a disminuir la humedad en los alimentos hasta alcanzar una condición en la que el material alimentario no puede ser deteriorado por microorganismos, esto a causa de la actividad del agua (a_w), que representa la disponibilidad de agua libre en un producto para propiciar reacciones químicas, crecimiento microbiano y germinación de esporas [11]. Se puede definir como la relación entre la presión parcial del vapor de agua inmediatamente sobre el producto húmedo y la presión parcial del agua pura a una temperatura equivalente. La actividad del agua se incrementa con el aumento de la temperatura y la presión. Por lo general, su valor oscila entre 0 y 1. Asimismo, la actividad del agua (a_w) puede ser expresada como [11]:

$$a_w = \frac{p}{p_o} \quad (2.1)$$

donde:

- p : presión parcial del vapor de agua sobre el producto húmedo a una temperatura específica
- p_o : presión parcial del agua pura en saturación y a la misma temperatura

Los estilos de secado se pueden clasificar en función del tipo de secado o en función de la circulación del aire por convección natural o convección forzada (secadores pasivos o secadores activos) [13], adicional a estas clasificaciones se encuentra la clasificación de los secadores según el método de funcionamiento (secador por lotes o secador continuo) y su clasificación según el modo de suministro de calor al proceso de secado (secador por convección, conducción, radiación o mixto) [11].

2.2. Secado solar

La forma más antigua de conservar alimentos es el secado solar. Desde hace miles de años, la humanidad ha utilizado la energía solar para secar productos perecederos, lo que permite la conservación natural de una gran variedad de alimentos [40]. Se entiende que el término secado de alimentos es la extracción deliberada del agua de los alimentos y su emisión al medio ambiente en forma de vapor, lo que evita el deterioro de los alimentos por parte de microbios o enzimas. Durante este proceso, los alimentos no se cocinan por sobrecalentamiento, lo que

mantiene en parte sus propiedades nutritivas.

2.2.1. Secado solar tradicional

La mayoría de los países en desarrollo todavía utilizan métodos tradicionales de secado. Los productos se secan en el suelo, sobre cemento o incluso en carreteras bajo el sol, donde se contaminan con polvo e insectos y se pierden por roedores, pájaros y otros animales. Además, las condiciones climáticas pueden ocasionar pérdidas en la cantidad y calidad del producto final [41].

2.2.2. Secado solar tecnificado

Para solucionar los problemas del secado solar tradicional se ha tecnificado el proceso de secado, obteniendo sistemas donde la energía solar puede utilizarse como fuente principal de energía (secador solar) o como fuente adicional (secador híbrido). El secador solar híbrido está diseñado para superar las limitaciones del secado solar tradicional, como la dependencia de las condiciones climáticas y la vulnerabilidad a factores ambientales [42]. El flujo de aire se produce naturalmente por convección o usando ventiladores por convección forzada [11].

2.2.3. Clasificación del secado solar

Según los autores, Patil y Gawande proponen una clasificación general donde el principal distintivo es el tipo de convección, sea convección natural, también denominados sistemas pasivos o de circulación natural, o convección forzada, también conocidos como sistemas activos. Figura 2.1 [43].

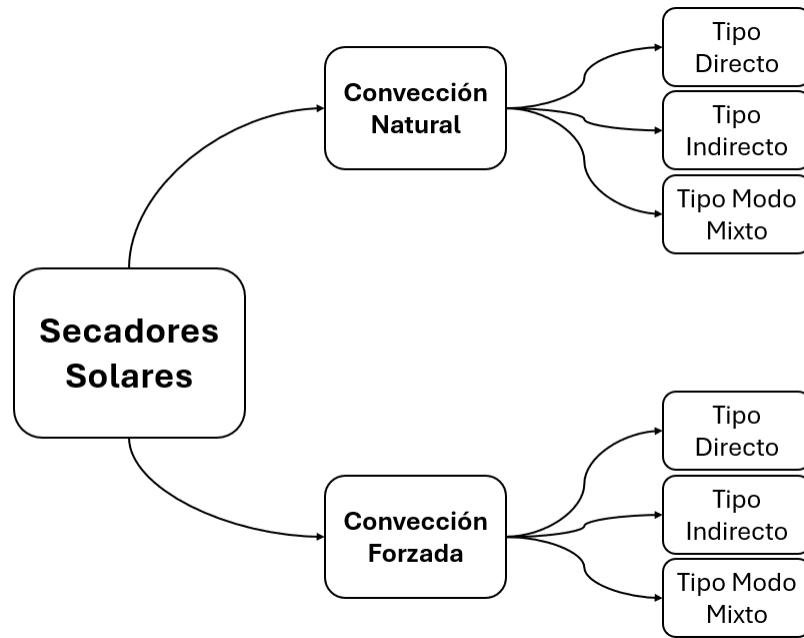


Figura 2.1: Clasificación de secadores solares según Patil y Gawande [43]

Sin embargo, Ekechukwu y Norton los clasifican principalmente en la disposición del diseño de los componentes del sistema y el modo de utilización de la energía solar. Figura 2.2 [44, 11].

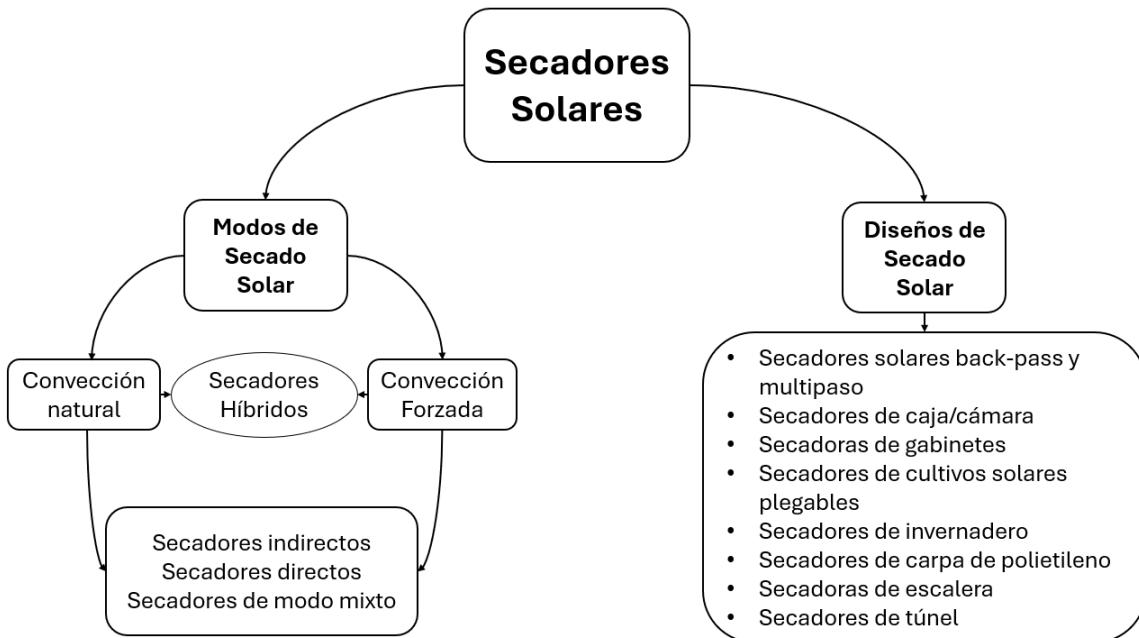


Figura 2.2: Clasificación de secadores solares según Ekechukwu y Norton [11].

2.2.4. Secadores del tipo convección natural

En los secadores solares de convección natural (pasivos), el aire se calienta y se mueve de manera natural gracias a la fuerza de flotación o a la presión del viento, o a una combinación de ambos. Un secador solar de convección natural típico se compone de una cámara recubierta de vidrio, en la cual el aire es calentado mediante la irradiancia solar. Esta cámara también funciona como cámara de secado y está conectada a una chimenea. Por lo general, son económicos, se construyen con materiales disponibles localmente y no dependen de la red eléctrica. Los secadores pasivos están diseñados para secar pequeñas cantidades de frutas y verduras, ya que requieren menos espacio en comparación con otros métodos de secado [44]. El proceso de secado mediante convección natural (o secado pasivo) produce el flujo de aire a través de fuerzas de flotación [45], un diseño básico de este tipo de secador es el que se encuentra en la Figura 2.3 en el cual los productos están ubicados en una placa bajo una tapa transparente permitiendo la transmisión directamente de la energía solar a los productos, la variación de temperatura entre el interior de la cámara y el exterior a temperatura ambiente provoca un flujo de aire por el cual se escapa la humedad [45].

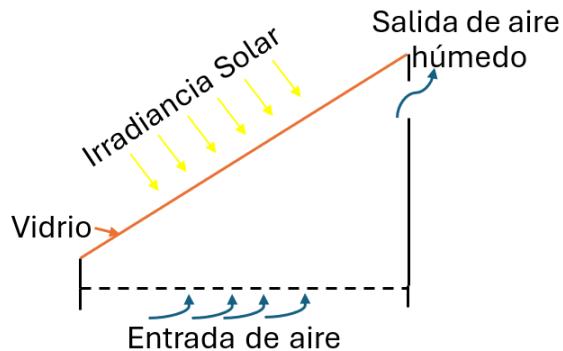


Figura 2.3: Secador solar de convección natural [45]

2.2.5. Secadores del tipo convección forzada

En los secadores de convección forzada (también llamados secadores activos), el aire fluye a través de un ventilador o soplador eléctrico, que funciona con energía eléctrica [45]. Un secador solar de convección forzada típico depende de la energía proveniente del sol como fuente principal de calor y utiliza ventiladores para garantizar la circulación del aire en la cámara de secado, como se muestra en la Figura 2.4. Al agregar un ventilador, se mejora el flujo de aire y se logran velocidades de secado mucho más altas en comparación con los secadores de convección natural. El flujo de aire necesario puede ser suministrado mediante

un ventilador eléctrico. Sin embargo, el consumo de energía eléctrica del ventilador en el caso de los secadores solares de convección forzada es muy bajo y puede ser alimentado por un módulo fotovoltaico independiente de la red eléctrica [11]. Un secador solar de convección forzada típico consiste en un colector de energía solar para calentar el aire, una cámara de secado y un ventilador o bomba para garantizar la circulación del aire de secado [44].

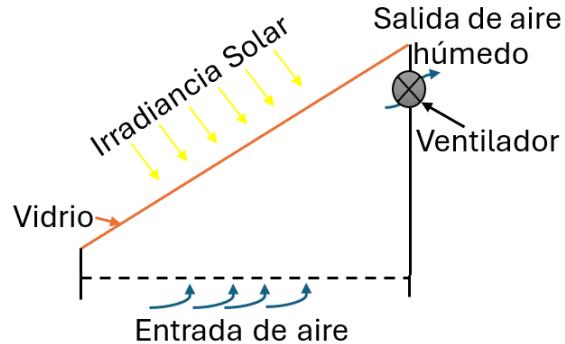


Figura 2.4: Secador solar de convección forzada [11, 45]

2.2.6. Secadores solares híbridos

Los secadores solares híbridos combinan la energía solar con sistemas de calefacción eléctricos o de combustibles fósiles. Figura 2.5 pueden tener ventiladores adicionales para garantizar la circulación del aire, funcionando en modo de convección forzada y pueden utilizar el aire calentado por energía solar y, en caso de no ser suficiente, se recurre a la calefacción operada por energía eléctrica o combustibles fósiles para alcanzar las temperaturas necesarias, como ocurre en la noche o en épocas de baja insolación, como las temporadas de lluvias. Este sistema se controla automáticamente para mantener las condiciones de secado adecuadas [44].

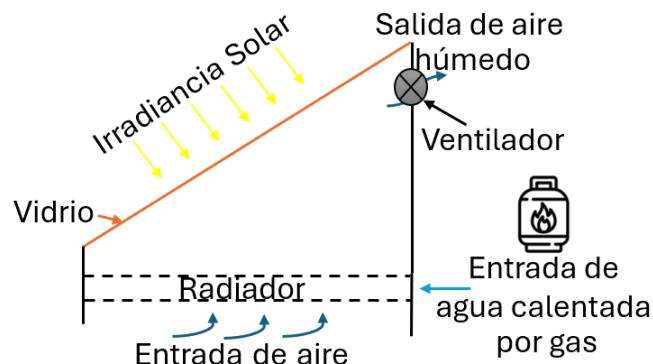


Figura 2.5: Secador solar híbrido

Comparando las 3 clasificaciones de secadores solares, Fudholi (2010) propone las siguientes ventajas y desventajas Tabla 2.1

Clasificación	Ventajas	Desventajas
Secadores Pasivos	Simples	Baja capacidad
	Bajos costos de capital y funcionamiento.	
Secadores Activos	Independiente del clima y condiciones ambientales Periodos de secado más cortos que los secadores pasivos Permitir un mejor control del secado.	Más sofisticados y caros que los secadores pasivos
Secadores Solares Híbridos	La capacidad de operar sin sol reduce la pérdida de producto. Puede ser más rápido que un secador tipo pasivo y activo.	Más costoso y puede causar dependencia del combustible/gas.

Tabla 2.1: Ventajas y desventajas de los diferentes tipos de secadores solares [46]

Adicional a esto y considerando las restricciones de los secadores solares, como la variabilidad climática y las horas de sol, sería provechoso hibridarlos con sistemas de energía tradicionales para asegurar la sostenibilidad del proceso de secado. Los secadores solares híbridos son de los sistemas más eficaces [45], dado que consiguen una tasa de secado superior y un tiempo de funcionamiento mayor en comparación con otras clases de secadores, esto sin considerar el alto costo que conlleva su fabricación y operación [46].

2.3. Contenido de humedad

La calidad de los productos está influenciada por el contenido y estado del agua, tanto libre como ligada, en productos alimentarios y no alimentarios. El método analítico más frecuente en el procesamiento de alimentos es el “contenido de humedad” el cual se refiere a la cantidad de agua en alimentos y otras sustancias [47]. Este puede ser indicado como porcentaje o como una proporción decimal, este representa el contenido de humedad que tiene un producto.[11]. El contenido de humedad presente en un producto puede expresarse de dos maneras: base húmeda (% w.b) y base seca (% d.b).

2.3.1. Base Húmeda

Utilizando base húmeda, los kg de agua por kg de materia es denotado como “ m ”. y se calcula de la siguiente manera [11]:

$$m = \frac{m_w}{m_w + m_d} = \frac{m_w}{m_T} \quad (2.2)$$

donde:

- m = contenido de humedad en base húmeda (wb)
- m_w = masa de agua en el producto
- m_d = masa de material seco del producto
- m_T = masa total del producto

2.3.2. Base seca

En base seca, los kg de agua por kg de materia seca de producto se denotan como “ M ” y se calculan de la siguiente manera:

$$M = \frac{m_w}{m_d} \quad (2.3)$$

donde:

- M = contenido de humedad en base seca (db)
- m_w = masa de agua en el producto
- m_d = masa de material seco del producto

Algunos autores representan el contenido de humedad de cualquier material preferentemente en base seca, mientras que para los productos agrícolas, se muestra en base húmeda [44].

La manera de determinar el contenido de humedad en un material o producto puede realizarse mediante diversas técnicas, siendo el método más habitual para determinar el contenido de humedad el secado en horno (Figura 2.6). En este procedimiento, se elige un pequeño volumen del producto para ser usado como muestra y se calienta en un horno a una presión y temperatura determinadas hasta que la humedad se disipa totalmente. El peso calculado es el peso en seco, mientras que la pérdida de peso se refiere a la cantidad de humedad presente [11].



(a) Inicio de la prueba (b) Final de la prueba

Figura 2.6: Analizador de humedad

2.3.3. Curvas de secado

Las características de secado de cualquier producto se pueden explicar con el uso de tres curvas trazadas [11]:

1. Variación del contenido de humedad en función del tiempo
2. Velocidad de secado en función del tiempo
3. Tasa de secado en función del tiempo del contenido de humedad

2.3.3.1. Cinéticas de secado

La cinética del secado se centra en cómo cambia la cantidad promedio de humedad con el tiempo. Por lo tanto, la cinética del secado aborda aspectos como la cantidad de humedad evaporada, el tiempo de secado, el consumo energético, entre otros [48]. No obstante, el cambio de humedad está condicionado por la transferencia de calor y masa entre la superficie del objeto, el entorno y el interior del material a secar. Es crucial entender que la intensidad del secado evidencia el cambio en la humedad a lo largo del tiempo, influenciado por parámetros como la temperatura, humedad, velocidad del aire, presión total, etc. Existen modelos para la representación de la cinética de secado, estos se clasifican generalmente como empíricos, semiteóricos y teóricos [48].

2.3.3.2. Curvas de velocidad de secado

Durante el proceso de secado, el cambio en el contenido de humedad de un producto se establece con el transcurso del tiempo y se representa a través de una curva. Esta curva detalla la disminución en la humedad de un producto y se determina la velocidad de secado correspondiente. La curva de secado varía de un producto a otro, ya que se basa principalmente en el tipo de material y su estructura [11, 44].

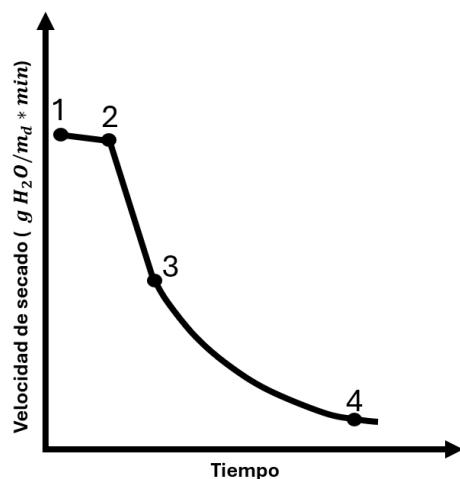


Figura 2.7: Curvas de velocidad de secado [44]

Durante el proceso de secado se pueden identificar 3 etapas (Figura 2.7) dichas etapas corresponden a lo que ocurre con el producto durante el proceso de secado.

- Periodo de velocidad constante (1-2): La superficie del producto se encuentra saturada y el desplazamiento de la humedad ocurre a través de una difusión a una velocidad constante.
- Primer periodo de velocidad descendente (2-3): La humedad del producto llegó a su nivel crítico de humedad y la superficie del producto carece de humedad suficiente para que se evapore con facilidad. El producto se seca de manera continua, formando una línea recta.
- Segundo periodo de velocidad descendente (3-4): La superficie del producto se encuentra prácticamente seca y la transferencia de humedad desde el interior hacia su superficie ocurre a una velocidad constante.

CAPÍTULO 3

REDES NEURONALES ARTIFICIALES

Las redes neuronales biológicas están constituidas por hasta 10^{11} neuronas conectadas entre sí, conformando el sistema nervioso y el cerebro. Tomando como base esta inspiración biológica, se han desarrollado sistemas inteligentes basados en modelos simplificados de las redes neuronales biológicas, estos sistemas procesan la información de forma no convencional y no requieren modelos de referencia, dando lugar a las redes neuronales artificiales [49].

3.1. Concepto de una RNA

Una red neuronal artificial (RNA o ANN por sus siglas en inglés) es un modelo computacional cuya estructura trata de asemejarse a la estructura de las neuronas cerebrales (neuronas biológicas). Una RNA puede aprender de datos con los cuales se entrena para reconocer patrones, clasificar o pronosticar eventos futuros [50]. El elemento fundamental de una RNA es la neurona, la cual en una red neuronal biológica consta de tres partes: las dendritas, que se encargan de recibir los impulsos eléctricos, el soma, que se encarga de realizar una suma de las señales que recibe y el axón que lleva la señal hacia otras células [49]. En una RNA, el modelo de una neurona se puede representar como se muestra en la siguiente figura, donde

cada neurona recibe una serie de entradas $x_1, x_2 \dots x_m$, cada una de estas ponderada por un peso específico $w_{k1}, w_{k2} \dots w_{km}$ que indica la importancia de esa entrada. Las entradas ponderadas se suman junto con el bias que representa el sesgo para producir la entrada neta de la neurona. Esta señal pasa a través de una función de activación que determina la salida de la neurona. Matemáticamente se puede describir este comportamiento de la siguiente manera: [51].

$$U_k = \sum_{j=1}^m W_{kj} \cdot X_j \quad (3.1)$$

$$y_k = \varphi(U_k \cdot b_k) \quad (3.2)$$

Donde φ representa una función de activación y estas pueden ser de tipo escalón o umbral, lineal a tramos, sigmoidal, trigonométricas, etc [49, 51].

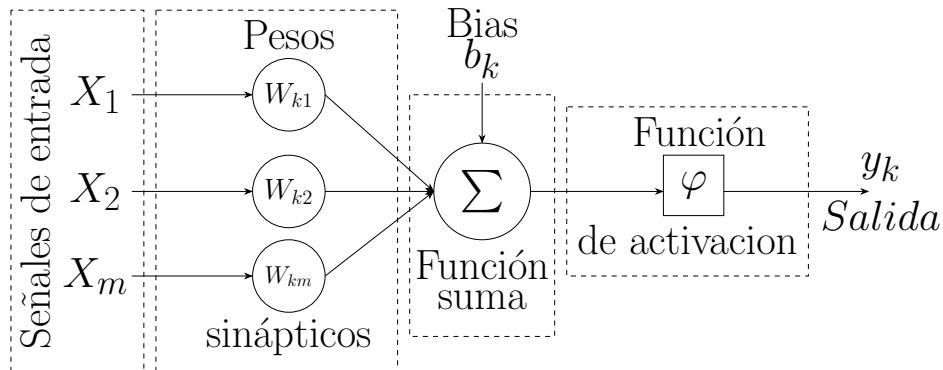


Figura 3.1: Modelo de una neurona artificial [51].

3.1.1. Arquitectura de redes neuronales

En términos generales, existen tres clases distintas de arquitecturas neuronales que se pueden identificar. Estas son redes neuronales unicapa, redes neuronales multicapa y redes neuronales recurrentes [49]. Redes neuronales unicapa: a diferencia de las neuronas biológicas que están organizadas por capas, estas consisten en una única capa de neuronas que conectan las entradas directamente con las salidas, un ejemplo de esta arquitectura de red es el perceptrón, o perceptrón simple. Redes neuronales multicapa: Estas redes constan de una o más capas ocultas las cuales se encuentran entre la capa de entrada y la capa de salida. Cada neurona de una capa se encuentra vinculada con todas las neuronas de la capa subsiguiente,

en caso de que no sea así, y falte alguna conexión entre las neuronas, se dice que la red es parcialmente conectada. Un ejemplo de esta arquitectura de red es el perceptrón multicapa (MLP por sus siglas en inglés). Redes neuronales recurrentes (RNN): A diferencia de las anteriores arquitecturas de red, esta se distingue por tener un lazo de retroalimentación que les permite mantener información a lo largo del tiempo.

3.1.2. Diseño de una red neuronal

En 1997, David H. Wolpert y William G. Macready demostraron a través de su renombrado teorema, “No Free Lunch Theorems for Optimization”, que no existe un algoritmo de optimización que sea universalmente superior para abordar todos los problemas de optimización existentes [52]. De manera análoga, autores como Simon S. Haykin sostienen que, aunque no existen reglas estrictamente definidas para el diseño de redes, existen ciertos procedimientos reconocidos por su efectividad, los cuales se clasifican en dos técnicas distintas [51].

1. Restringir la arquitectura de la red, lo que se logra mediante el uso de conexiones locales conocidos como campos receptivos
2. Restringir la elección de pesos sinápticos, que se implementa mediante el uso de peso compartido

Aplicando estas dos técnicas se podría reducir significativamente el número de parámetros libres, no obstante, el espacio de todas las arquitecturas neuronales posibles es vasto, ya que incluye combinaciones infinitas de capas, conexiones y funciones. Este espacio es comparable en magnitud al espacio de todas las funciones diferenciables que pueden ser representadas por estas arquitecturas [53]. Por consiguiente, incluso al elegir diseñar una arquitectura neuronal a partir de componentes o estructuras ampliamente adoptadas, existe una notable diversidad de alternativas a evaluar. Estas incluyen, entre otras, el número de capas ocultas, el número de neuronas por capa, la función de activación, la conectividad entre las capas y la inicialización de parámetros, por lo cual existen algunas maneras de explorar la mayoría de combinaciones posibles, como lo son los métodos evolutivos [54] o análisis paramétricos.

3.1.3. Proceso de aprendizaje

Como se mencionó anteriormente, las redes neuronales artificiales (RNA) surgen de una inspiración biológica y lo mismo ocurre con el proceso de aprendizaje, así como para los

humanos existen diferentes maneras de aprender algo, en las redes ocurre lo mismo y estas se pueden clasificar según el autor en dos categorías [51] o más de tres categorías [55].

3.1.3.1. Aprendizaje supervisado

El aprendizaje supervisado o aprendizaje a partir de ejemplos consiste en el uso de datos o conjuntos de datos previamente etiquetados, acompañados de la salida correcta para enseñar o entrenar algoritmos y de esta manera ser capaz de replicar la salida de la forma más parecida a la deseada. Este tipo de aprendizaje es utilizado en el aprendizaje memorístico (rote learning), diferentes modelos de clasificación como las listas o árboles de decisión, máquinas de vector de soporte (SVM), Naive Bayes, regresión logística o lineal, Bosque aleatorio, K vecino más cercano. Métodos que se caracterizan por su principal enfoque en categorizar datos en clases o categorías predefinidas.

3.1.3.2. Aprendizaje no supervisado

El aprendizaje no supervisado, también conocido como aprendizaje por observación o “sin profesor”, consiste en el uso de datos o conjuntos de datos sin etiqueta. Es aquí donde se observa la principal diferencia con el aprendizaje supervisado. En este tipo de aprendizaje, se busca que el sistema sea capaz de encontrar patrones y relaciones por sí solo, sin que exista información adicional o la “supervisión”, obligando al sistema a decidir sobre cómo agrupar o clasificar los datos del conjunto de entrenamiento.

3.1.3.3. Aprendizaje reforzado

Este tipo de aprendizaje proviene de una de las formas mediante la cual animales y algunos humanos aprenden, el aprendizaje animal implica alterar su conducta basándose en la información obtenida de su entorno, lo que les permite prever situaciones futuras y adaptar su comportamiento. Siguiendo con el comportamiento animal, la mejor forma de describir este proceso de aprendizaje es con una situación común, cuando nuestra mascota hace algo bien, normalmente se le felicita, con una caricia o algún premio, en cambio, si se comporta de una forma no deseada, se le suele regañar o castigar, regresando al aprendizaje automático este se puede describir como un aprendizaje a prueba y error, en el cual, tras una experimentación exitosa, se recompensa a la red (refuerzo positivo); en el caso de fallar, se penaliza (refuerzo negativo). Realimentando la red, el refuerzo positivo es la señal que sirve como señal de su-

pervisión, por lo tanto, este tipo de aprendizaje puede clasificarse en un aprendizaje de tipo supervisado [55].

3.2. El perceptrón

El perceptrón es considerado por diferentes autores como la forma más simple de una red neuronal, siendo ampliamente utilizado en la clasificación de patrones linealmente separables. En 1958, Rosenblatt propone el perceptrón, dando inicio al primer modelo basado en el aprendizaje supervisado. Este método se basa en una sola neurona con pesos ajustables y un umbral, (donde los pesos se refieren a valores numéricos asignados a cada conexión entre las entradas y la neurona del perceptrón, y el umbral o bias es un valor adicional utilizado para ajustar la salida antes de la aplicación de la función de activación) lo que permite determinar si un patrón dado pertenece a una clase en particular o no. Teniendo como principal objetivo lograr una correcta separación de los diferentes patrones a través de un hiperplano o dicotomía, permitiendo clasificarlos de manera eficiente y precisa [49, 51]. Este puede ser representado de la misma forma que un modelo de una neurona artificial, donde la señal sigue el siguiente flujo, el cual se muestra en la siguiente Figura 3.2.

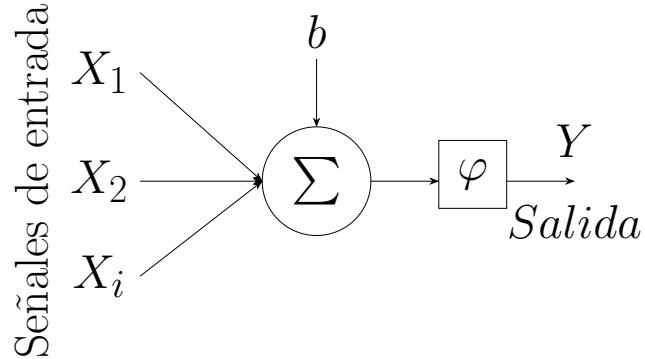


Figura 3.2: Representación de un perceptrón Fuente: [51].

El perceptrón se puede describir matemáticamente de la siguiente forma:

$$Y = \left(\sum_{i=1}^m W_i \cdot X_i + b \right) \cdot \varphi \quad (3.3)$$

donde el algoritmo de aprendizaje del perceptrón consiste en:

1. Inicialización: Se inicializan los pesos y el bias en valores aleatorios o 0

2. Entrenamiento:
 - a) Calcular la salida predicha “Y”
 - b) Calcular el error $e = y - Y$ donde “y” es la salida deseada o real
 - c) Actualizar los pesos $w = w + \alpha \cdot e \cdot x$ donde “w” es el vector de pesos del perceptrón, “ α ” es la tasa de aprendizaje, “e” el error diferencial y “x” el vector de entrada
 - d) Actualizar el sesgo $b = b + \alpha \cdot e$
 - e) Repetición del proceso hasta que se cumpla algún criterio como puede ser un error mínimo deseado o un numero de épocas
3. Predicción: Emplear el modelo previamente entrenado para determinar la salida correspondiente a nuevas entradas que no pertenecieron al conjunto de datos de entrenamiento.

3.3. El perceptrón multicapa

En el libro de Minsky y Papert (1969) se presentaba un análisis detallado del perceptrón, causando un estancamiento en el desarrollo de las redes neuronales artificiales causado por su mayor desventaja presentada por Minsky y Papert, siendo esta su falta de habilidad para solucionar problemas de clasificación que no sean separables linealmente, y no fue hasta cinco años después, en 1974, cuando P. Werbos desarrolló el perceptrón multicapa, el cual permite resolver este problema [51]. El perceptrón multicapa desarrollado por P. Werbos tiene una estructura de una capa oculta como mínimo. Iniciando con el desarrollo del perceptrón multicapa (MLP por sus siglas en inglés). El perceptrón multicapa tiene tres características básicas que resaltan entre todas [51]:

1. La red posee una función de activación lineal o no lineal en su modelo.
2. La red alberga una o varias capas ocultas entre la capa de entrada y la capa de salida.
3. La red muestra un elevado nivel de conexión, cuyo rango se determina por los pesos sinápticos de la red.

Sin embargo, estas características son responsables de las deficiencias que tiene el perceptrón multicapa. La existencia de una forma distribuida de no linealidad y la elevada interconexión de la red dificultan la realización de un análisis teórico de un perceptrón multicapa. De la misma manera, la utilización de neuronas o capas ocultas complica la visualización del proceso de aprendizaje [51]. La Figura 3.3 representa un perceptrón multicapa con dos capas ocultas y

una capa de salida, todo conectado entre sí y el flujo de la señal avanza de izquierda a derecha o hacia adelante capa por capa, las señales son de dos tipos: señal de información, la cual va desde la capa de entrada hacia la de salida, y la señal de error que va desde la capa de salida hacia la capa de entrada.

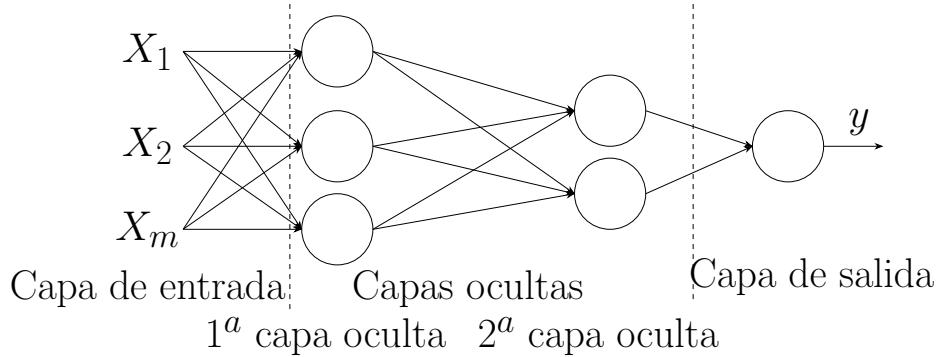


Figura 3.3: Modelo de una red neuronal del tipo perceptrón multicapa [49].

La función de las neuronas ocultas es actuar como detectores de características que desempeñan un papel fundamental. A medida que avanza el proceso de aprendizaje, las neuronas empiezan a “descubrir” características fundamentales caracterizando los datos de entrenamiento. Esto se realiza mediante una transformación no lineal de los datos de entrada, creando un nuevo espacio denominado “espacio de características”. En este espacio, se simplifica el proceso de clasificación patrones, debido a que esto se lleva a cabo mediante una transformación no lineal de los datos, resultaría inviable utilizar un perceptrón simple para tal propósito [51].

3.3.1. Aprendizaje por lotes

En el método por lotes de aprendizaje supervisado, los ajustes a los pesos de las conexiones en una red neuronal de perceptrón multicapa se realizan después de presentar todos los ejemplos del conjunto de entrenamiento, lo cual se considera una “época” de entrenamiento. En otras palabras, la función de costos en este método se basa en el error promedio, calculado sobre todos los ejemplos del conjunto. Los ajustes en los pesos de la red se hacen al final de cada época, en lugar de después de cada ejemplo individual. Así, se puede observar la evolución del aprendizaje de la red trazando el valor del error promedio frente al número de épocas de entrenamiento.

3.3.2. Aprendizaje en línea

Este es un método de aprendizaje supervisado en el que los ajustes de los pesos sinápticos de la red neuronal se realizan después de cada ejemplo de entrenamiento, en lugar de procesar todo el conjunto de datos o al final de cada época como ocurre en el aprendizaje por lotes. Esto permite a la red actualizar los pesos continuamente ajustándolos de manera más rápida y dinámica, adaptándose a nuevos datos de manera inmediata. Dado que los datos de entrenamiento se presentan a la red de forma aleatoria, el uso del aprendizaje en línea facilita la búsqueda en el espacio de peso multidimensional de naturaleza estocástica, es por esta razón que el método de aprendizaje en línea a veces es denominado método estocástico. Esta estocasticidad tiene el efecto deseable de hacer menos probable que el proceso de aprendizaje quede atrapado en un mínimo local, ventaja sobre el aprendizaje por lotes[51], además, el ajuste continuo de los pesos de manera iterativa, es decir, dato por dato, facilita el aprovechamiento de la redundancia presente en los datos de entrenamiento, ya que los ejemplos se presentan de manera individual en lugar de en lotes, como ocurre en el aprendizaje por lotes.

3.3.3. Generalización

La generalización se refiere a la capacidad de las redes neuronales artificiales para aplicar el conocimiento adquirido durante la fase de entrenamiento a un conjunto de datos nuevos que no fueron utilizados para el entrenamiento. En otras palabras, cómo la red neuronal puede predecir o clasificar adecuadamente las entradas nuevas que no forman parte del conjunto de entrenamiento previo [49]. En el aprendizaje mediante retropropagación, es habitual iniciar con una muestra de datos de entrenamiento y se emplea el algoritmo de retropropagación para calcular los pesos sinápticos de un perceptrón multicapa, codificando la mayor cantidad de ejemplos de entrenamiento en la red, el término “generalización” se toma prestado de la psicología [51]. Autores como Simon S. Haykin consideran que el proceso de aprendizaje de una red neuronal se puede “imaginar” como un “ajuste de curvas”. En este punto de vista, podemos ver la generalización como el resultado de una interpolación no lineal efectiva en lugar de una propiedad mágica de las redes neuronales. La red realiza una interpolación útil principalmente porque los perceptrones multicapa con funciones de activación continua producen funciones de salida también continuas [51].

3.4. Algoritmos Bio-Inspirados

Los algoritmos bio-inspirados son un tipo de algoritmo computacional inspirado en la naturaleza como los procesos y sistemas biológicos, para resolver problemas en áreas como la optimización, búsqueda, clasificación, aprendizaje automático entre otros [56, 57].

3.4.1. Algoritmos Genéticos

Los algoritmos genéticos (AG) también conocidos como algoritmos evolutivos (AE) son técnicas adaptativas empleadas para solucionar problemas relacionados con optimización y búsqueda. Se fundamentan en los procesos genéticos de los seres vivos. Charles Darwin en el origen de las especies estableció por primera vez que las poblaciones naturales a lo largo de generaciones evolucionan de acuerdo con los principios de selección natural y “supervivencia del más apto”. Siguiendo estos principios, los algoritmos genéticos pueden imitar este proceso y crear soluciones a problemas del mundo real [57]. Un algoritmo genético tradicional se puede representar como se muestra en la siguiente Figura 3.4

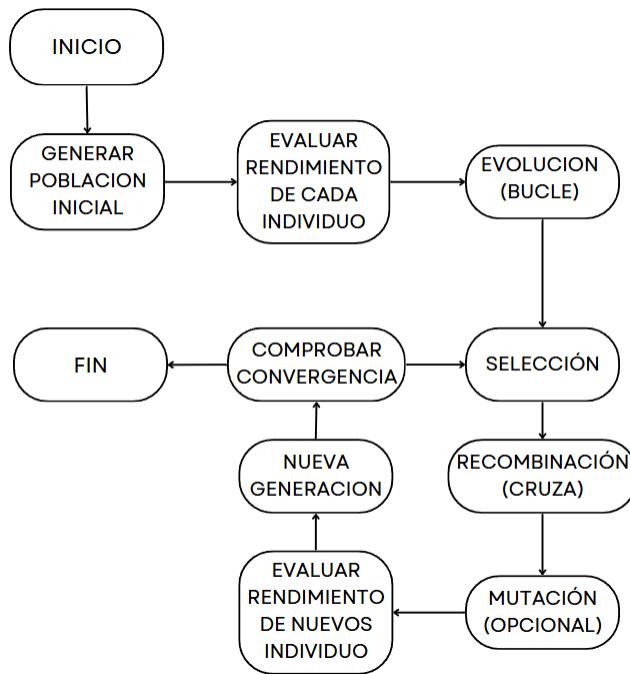


Figura 3.4: Representación de un AG tradicional [57].

Algunos conceptos importantes en los algoritmos evolutivos son:

- **Selección:** La selección de padres es un proceso que se lleva a cabo de forma aleatoria, utilizando una variedad de métodos para aumentar la probabilidad de que los individuos más destacados de una comunidad sean elegidos para cruzarse con otro parente seleccionado. Esto es crucial asegurar que las personas más talentosas de la población tengan una mayor probabilidad de reproducirse en comparación con las personas menos talentosas. Sin embargo, es importante dar la oportunidad de selección a los individuos con un rendimiento inferior, ya que estos pueden tener características útiles en su genotipo. Lo que puedo ayudar a resolver el problema, para lograr esto existen diferentes métodos para decidir cómo y cuándo darles la oportunidad a estos individuos de reproducirse como la selección aleatoria, el ranking lineal, a selección por ruleta, el emparejamiento variado inverso y la selección por torneo.
- **Cruce:** Después de la selección, los individuos elegidos se transforman en los “padres”, quienes se unirán en pares para generar nuevas soluciones o “hijos”, que poseen la información genética de ambos progenitores siendo los nuevos aspirantes para la próxima generación, este proceso se denomina como cruce y equivale a la etapa reproductiva. El cruce se asocia con un valor probabilístico que representa la probabilidad de que los “Padres” tengan o no descendencia estos valores de probabilidad suelen ser elegidos entre el 0.6 y el 0.9. Esto dependerá del problema en cuestión.
- **Mutación:** En la mutación, cada miembro de la población la experimenta de manera diferente. Debido a que de forma aleatoria se altera de manera aleatoria el valor de alguno de los genes del genotipo de un individuo particular en nuestra población, por lo que es poco probable por no decir imposible que obtengan la misma mutación. Esta operación es crucial para el algoritmo porque facilita la exploración del espacio de búsqueda del problema de una forma que solo podría realizarse mediante la operación de cruce.
- **Evaluación:** Su propósito es dirigir la búsqueda dentro del espacio de soluciones del problema. En esta etapa, es necesario obtener un valor real que refleje el nivel de adaptación o funcionamiento del individuo como solución a nuestro problema a partir del fenotipo del individuo. Esta evaluación suele comenzar con una función objetivo o función de “fitness”.
- **Reemplazo:** Es el proceso por el cual los hijos reemplazan a todos o a algunos padres de la población anterior. Existe una variedad de maneras de realizar este proceso. Algunos se asignan en función del número de hijos que reemplazan a un parente como lo son los modelos generacionales y estacionarios. El modelo generacional implica la creación de una población completamente nueva en cada generación, mientras que el modelo estacionario solo algunos de los padres son reemplazados por nuevos individuos.

- **Elitismo:** El elitismo consiste en como su nombre lo indica en preservar a las mejores personas esto a través de las generaciones para que puedan transmitir su valiosa información genética a las generaciones futuras y de esta forma ir mejorando la “raza”. Este sistema protege a los individuos más destacados de una comunidad de los procesos de selección, cruce y mutación, asegurando que permanezcan intactos en la próxima generación.

Algunos ejemplos de algoritmos evolutivos que utilizan estos conceptos son:

3.4.2. Optimización de enjambre de partículas

La optimización de enjambre de partículas (PSO por sus siglas en inglés) fue presentada por primera vez por Kennedy y Russell [58] la cual se inspira principalmente en las parvadas de aves y los cardúmenes. Un enjambre es una población de soluciones, y cada partícula de un enjambre es un individuo. Un conjunto de n partículas se denomina enjambre. Un vector de posición x_i de dimensión D para cada partícula i se evalúa utilizando una función de aptitud $f(\cdot)$. Con base en los resultados de la evaluación, la mejora en las partículas nuevas en comparación con las antiguas es fácil de medir. Considerando que las partículas se mueven iterativamente dentro del espacio de búsqueda, lo cual se logra ajustando su posición mediante el uso de la velocidad v_i , un cambio de posición apropiado al aplicar la ecuación 3.4 a cada partícula, la velocidad cambia para cada iteración t [56].

$$v_i(t+1) = \omega v_i(t) + c_1 r_1 (P_{ibest} - x_i) + c_2 r_2 (P_{gbest} - x_i) \quad (3.4)$$

donde:

- $v_i(t)$: Velocidad de la partícula i en el instante t .
- ω : Factor de inercia o peso de inercia, controla la exploración global frente a la explotación local.
- r_1 y r_2 : Variables aleatorias distribuidas uniformemente dentro de $[0, 1]$, introducen estocasticidad en la exploración
- c_1 y c_2 : Factores de ponderación, también llamados parámetros cognitivos y sociales (Controlan el comportamiento de las partículas).
- Ω : peso de inercia, que disminuye linealmente

- P_{ibest} y P_{gbest} : Representan la mejor posición visitada por una partícula y la mejor posición visitada por el enjambre antes de la iteración actual t, respectivamente.

La actualización de la posición se aplica mediante la ecuación 3.5 en función de la nueva velocidad y la posición actual.

$$x_i(t+1) = x_i(t) + v_i(t+1) \quad (3.5)$$

donde:

- $x_i(t)$: Posición de la partícula i en el instante t.

3.4.3. Colonias de abejas artificiales

Karaboga presentó el algoritmo ABC (artificial bee colony algorithm) por primera vez en 2005, este algoritmo se basa en el comportamiento de las abejas cuando buscan alimento [59]. El ABC se basa en cómo las abejas melíferas buscan alimento. El enjambre de abejas melíferas es uno de los enjambres naturales que trabajan juntos para encontrar alimento utilizando la comunicación, la memorización del entorno, el almacenamiento y el intercambio de información y la toma de decisiones. El enjambre se actualiza, asigna tareas de forma dinámica y avanza mediante el aprendizaje y las enseñanzas sociales según los cambios en el entorno [60]. Las abejas pertenecen a tres categorías:

1. Empleadas: abejas alimentadas por una fuente de alimento
2. Observadoras: abejas que observan cómo bailan las otras abejas y eligen fuentes de alimento basándose en cómo bailan.
3. Exploradoras: abejas que abandonan su fuente de alimento para encontrar otra.

Cada fuente de alimento es una posible solución al problema de optimización y, como en la naturaleza, es más probable que las personas se sientan atraídas por fuentes con una mayor cantidad de alimento [56]. En la siguiente Figura 3.5 se describe el funcionamiento del algoritmo ABC.

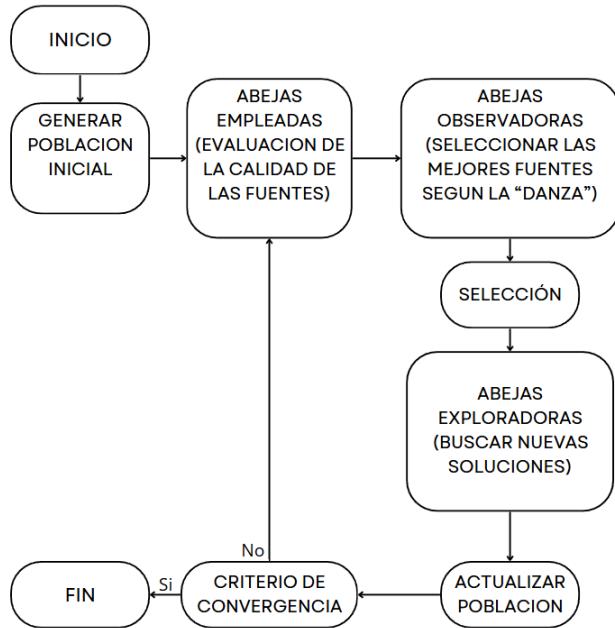


Figura 3.5: Representación de un ABC

El cual se repite hasta que se cumpla un criterio de parada, como alcanzar un número máximo de iteraciones o la convergencia de las soluciones.

3.5. Algoritmos evolutivos para el entrenamiento de redes neuronales

Como se indicó previamente, la estructura o topología de una red neuronal artificial es esencial para establecer su capacidad de aprendizaje y generalización. Una red con escasas neuronas puede enfrentar un gran desafío al aprender una tarea (Underfitting), sin embargo, tener demasiadas neuronas puede adaptar excesivamente su salida a los patrones de entrenamiento (Overfitting), lo que disminuye su habilidad para generalizar ante nuevos patrones. Una de las técnicas más usadas para seleccionar la arquitectura es mediante un proceso de prueba y error, variando los parámetros hasta obtener el desempeño deseado [55].

Existen métodos como aproximaciones automáticas, como los algoritmos incrementales, el cual comienza con una red neuronal pequeña y va agregando neuronas o capas conforme a los criterios establecidos, o el método pruning, el cual hace todo lo contrario; empieza con una red neuronal gigante y va eliminando conexiones [54]. Los algoritmos evolutivos son técnicas de

búsqueda altamente eficaces y potentes para localizar la mejor solución en un amplio espacio de búsqueda, incluso si ese espacio cuenta con óptimos locales. Estos algoritmos se pueden aplicar a tres aspectos de las redes neuronales artificiales: Los pesos iniciales de la conexión, la arquitectura de la red y las reglas de aprendizaje [61].

3.5.1. Elección de los pesos iniciales

En diversos experimentos, Thimm y Fiesler descubrieron que la inicialización de los pesos de una red neuronal es esencial para conseguir una convergencia rápida en las redes neuronales del tipo MLP, dado que los resultados del entrenamiento de la red se determinan por el punto del espacio de búsqueda del que se inicie [62]. La selección de estos pesos iniciales en su método más común es seleccionar los pesos aleatoriamente, siendo este el método por defecto en Matlab. En la literatura se muestran diversos métodos para la selección de estos pesos algunos requieren un análisis estadístico de los datos de entrenamiento, otros proponen rangos de inicialización que dan buenos resultados para una aplicación en específico, pero ninguno de los métodos propuestos presenta una justificación matemática; en su mayoría, son métodos experimentales.

3.5.2. Elección de la arquitectura de la red

El diseño de la arquitectura de una red neuronal artificial es importante debido a que esta definirá su capacidad de aprendizaje y generalización. La elección puede trabajarse como un problema de búsqueda en el espacio de todas las arquitecturas limitadas para cada problema donde cada punto representa una arquitectura de red posible [61]. Siendo este un problema típico de optimización que puede ser resuelto por AG.

3.5.3. Evolución de la regla de aprendizaje

Se basa en el uso de algoritmos genéticos para el ajuste de los parámetros como la tasa de aprendizaje y el momento [61], siendo más populares los optimizadores, los cuales son algoritmos o métodos que se utilizan para cambiar los atributos de la red neuronal. Algunos de estos son Gradiente descendente estocástico (SGD), RMSprop, Adam, Momentum, NAG, Adagrad, entre otros.

3.6. El control en el proceso de secado

El control en el proceso de secado tiene como objetivo mantener las condiciones operacionales lo más cercanas posible a los puntos de consigna, compensando cualquier desviación potencial. En la mayoría de los casos, el resultado objetivo es el contenido de humedad final, y la variación en el contenido de humedad final determina el desempeño del control. La Figura 3.6 muestra la estructura del control universal asistido por computadora que utiliza dos circuitos de retroalimentación de proceso y producto [7].

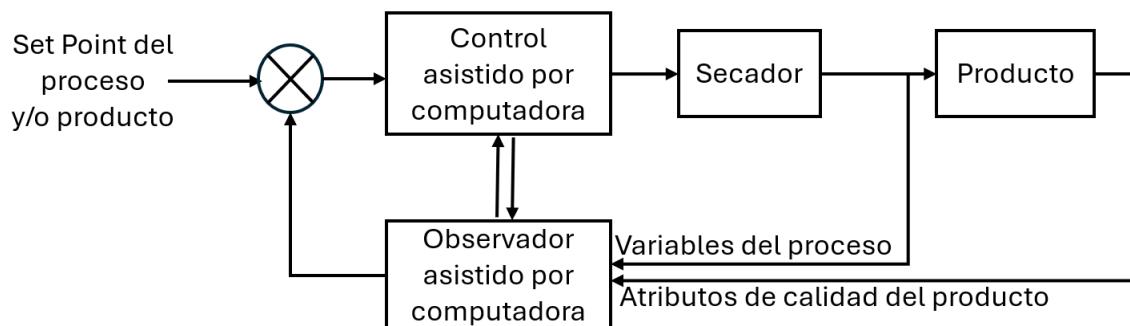


Figura 3.6: Estructura de un sistema de control centrada en la calidad del producto.

Los sistemas de control asistidos por computadora constan de dos partes diferenciadas, el controlador, el cual ajusta las condiciones del proceso en función del observador para obtener la calidad deseada, y el observador, el que observa y colecta información acerca de las variables del proceso o los cambios en la calidad del producto.

Para lograr atributos de calidad deseables (contenido de humedad, tamaño, color y textura) del producto seco. El sistema de control se vuelve sensible a los cambios en la calidad de los alimentos a través de parámetros de calidad monitorizados por sensores, como resultado, el sistema de control ajusta los parámetros operativos en relación con la calidad del producto, y el objetivo general del proceso de secado sería mantener el producto dentro de especificaciones de calidad estrictas. El sistema de control utiliza esta retroalimentación, empleando algoritmos como lo son ON/OFF, un proporcional-integral-derivado (PID) o neuro-difuso, siendo estos sistemas de control tradicionales [7], no estando presentes los sistemas de control inteligentes, los cuales son sistemas que toman decisiones y controlan procesos de manera autónoma y adaptativa utilizando técnicas de inteligencia artificial y computación [63]. En la Tabla 3.1 los autores Hao y colaboradores presentan una comparativa entre la termodinámica tradicional y el aprendizaje automático.

Cuestiones comparativas		Tipo de método de predicción	
		Aprendizaje Automático	Termodinámica tradicional
Ámbito de aplicación	Primera etapa de diseño	No	Si
	Etapa de predicción del funcionamiento del sistema	Si	Si
Condiciones necesarias para la aplicación	Gran cantidad de datos de muestra	Si	No
	Nivel de especialización	Bajo	Alto
Ventajas y desventajas	Ventajas	Requisitos de nivel profesional bajo	Capacidad para analizar el mecanismo
	Desventajas	Una gran cantidad de datos de muestra	Modelado complejo

Tabla 3.1: Comparativa aprendizaje automático y termodinámica tradicional [64]

3.7. Control inteligente

Cuando vamos a secar un producto, se tiene una incertidumbre sobre las características estructurales de cada alimento y esto genera una incertidumbre sobre su comportamiento ante las diferentes condiciones operacionales del secador. Mismas que tienen un efecto particular sobre la cinética de secado, es decir, sobre su comportamiento ante diferentes condiciones de secado y cuando se empiezan a tener este tipo de incertidumbres, cuando las características no son siempre las mismas, o el medio ambiente nos puede generar perturbaciones, todas estas no linealidades hacen que un sistema de control tradicional como lo sería un PID quede descartado, ya que no podría lidiar con estas no linealidades, ocasionando un muy alto error. Es por eso que las redes neuronales se han establecido como una técnica para el modelado y control de sistemas lineales o no lineales, permitiendo solucionar una gran cantidad de problemas con una misma técnica. Esto ha ocasionado un aumento de popularidad debido a su gran número de aplicaciones, siendo el control uno de los beneficiados. En muchos casos, se puede combinar el control tradicional y el control inteligente para optimizar un controlador existente. Esto presenta algunas ventajas y desventajas, como ventajas tenemos, su facilidad y gradual implementación, la mejora significativa en el seguimiento sin un aumento significativo en el ruido, en cuanto a sus desventajas se requiere un controlador tradicional estabilizante en lazo cerrado, no se reduce el efecto de perturbaciones en el sistema [49]. En la Tabla 3.2 se muestra una pequeña comparativa entre ambos controles.

	Control Tradicional	Control Inteligente
Funcionamiento	Basado en modelos matemáticos predefinidos.	Inspiración biológica, psicología, fisiología. Aprende de los datos para modelar y controlar el sistema.
Adaptabilidad	Muy poco adaptable, requiere reajuste manual y cálculos nuevos.	Altamente adaptable, se ajusta automáticamente y aprende de sus errores.
Complejidad de sistemas	Ideal para sistemas lineales y no lineales	Ideal para sistemas lineales y no lineales. Facilidad para controlar sistemas no lineales.
Parametrización	Requiere conocimientos profundos para parámetros fijos.	Aprende los parámetros óptimos de los datos, por lo que requiere una gran cantidad de datos.
Mantenimiento	Menos mantenimiento una vez configurado, siempre y cuando no se altere el sistema original.	Requiere entrenamiento y ajuste continuo, que puede ser manual o automático.
Interpretabilidad	Lógica de control fácilmente interpretable.	La lógica de control puede ser compleja y poco interpretable en ciertos casos.
Ejemplos	Control PID, PI, PD, ON/OFF, Modo deslizante	Redes neuronales dinámicas, recurrentes, convolucionales, recursivas, IA, perceptrón multicapa.

Tabla 3.2: Comparativa control tradicional y control inteligente

La decisión al seleccionar un control depende de la complejidad del sistema, los datos disponibles y la necesidad de interpretación.

CAPÍTULO 4

METODOLOGÍA

4.1. Materiales

El secador solar evaluado (Figura 4.1), se encuentra ubicado en las coordenadas 23.9916, -104.7268 dentro de las instalaciones del Centro de investigación en Materiales Avanzados (Figura 4.1b). El sistema de secado consta de un circuito hidráulico (Figura 4.1a) El sistema opera mediante el calentamiento del agua mediante cuatro colectores solares de placa plana, la cual es conducida a través de un intercambiador de calor antes de ser almacenada en un tanque térmico que cierra el circuito, permitiendo su reinicio. La energía necesaria para el bombeo del agua y el suministro de aire a la cámara de secado es proporcionada por un panel fotovoltaico o por la electricidad de la red.

Componente	Detalles	Especificación
Colector solar	Marca: Módulo Solar	Área: $2.5 m^2$
Intercambiador de calor	Aqua-aire	Área: $0.16 m^2$
Tanque de almacenamiento térmico	Marca: Calorex	Capacidad: 300 L
Panel fotovoltaico		Potencia: 300 W

Tabla 4.1: Componentes secador solar tipo tunel



(a) Modelo 3D

(b) Diseño experimental

Figura 4.1: Secador solar tipo túnel

4.1.1. Descripción de la cámara de secado

La cámara de secado está formada por una sección cuadrada cubierta de vidrio translúcido (Figura 4.2a). Dentro de la cámara de secado, hay tres bastidores con una capacidad de 10 charolas cada una de $0.3 \text{ m} \times 0.3 \text{ m}$ dando una capacidad total de 2.7 m^2 y debajo de estos una celda de peso para registrar la pérdida de peso en tiempo real (Figura 4.2b). Esta cámara de secado está acoplada a un ventilador axial de $12V$ con velocidad variable de 0 a 2.8 m/s el cual forza el aire desde el exterior, haciéndolo pasar por el intercambiador de calor acoplado a este, el cual es un intercambiador de calor agua-aire de 0.16 m^2 . Para el calentamiento del agua se utilizan 4 colectores solares de la marca “módulo solar” modelo MS 2.5 cada uno con un área de 2.5 m^2 cada uno.



(a) Vista isométrica

(b) Vista lateral

Figura 4.2: Cámara de secado

4.1.2. Productos a secar

Para la obtención de datos de secado se obtuvo de manera experimental el proceso de secado de diferentes alimentos, con un intervalo de tiempo de 5 min. esto con el objetivo

de tener datos para el entrenamiento de la red neuronal. Los alimentos que se secaron se encuentran en la Tabla 4.2. Los experimentos se llevaron a cabo en el secador solar tipo túnel (Figura 4.1). El procedimiento que se siguió para cada uno de los experimentos consiste:

- Adquisición del producto
- Proceso de limpieza y desinfección
- Corte del producto en rebanadas, en caso necesario
- Encendido, configuración y calibración del sistema de adquisición de datos
- Distribución del producto en las charolas del secador, reservando una muestra para medir el contenido inicial de humedad
- Puesta en marcha del sistema
- Espera hasta la completa deshidratación del producto
- Recolección del producto

Alimento	Cantidad
Manzana Canatlán	4.6 kg
Plátano Chiapas	2.8 kg
Uva globo rojo	8.5 kg
Pulpa bola de res	12.5 kg
Chile poblano	1.5 kg
Casca de naranja	3 kg
Limón agrio sin semilla	3 kg

Tabla 4.2: Productos seleccionados para obtención de datos experimentales

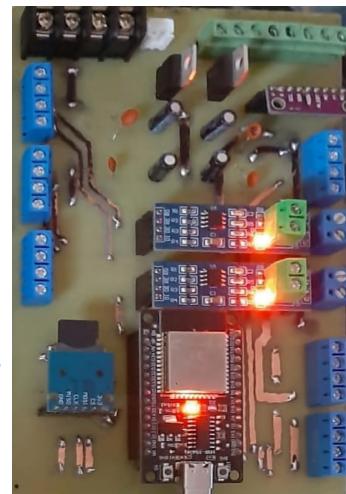
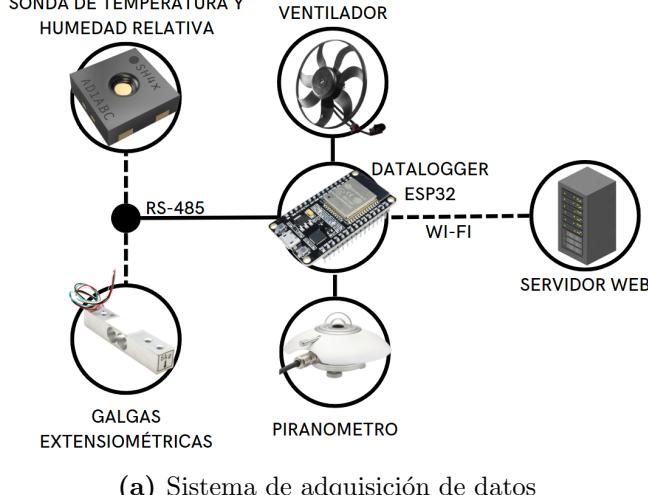
4.1.3. Adquisidor de datos

El sistema está conformado por cuatro sondas diseñadas para medir la temperatura y la humedad relativa dentro de la cámara de secado. Dichas sondas se encuentran distribuidas a lo largo del túnel en intervalos de 40 cm (Figura 4.3), compartiendo el mismo bus de comunicación con tres celdas de carga. Estas celdas de carga se calibran utilizando un peso certificado de 300 g y son puestas a cero antes de cada ensayo (Figura 4.3).



Figura 4.3: Distribución de los sensores dentro de la cámara de secado

Ambas configuraciones cuentan con microcontroladores independientes, los cuales son responsables de gestionar los sensores y de establecer comunicación con el microcontrolador principal (ESP32) (Figura 4.4b), además de estar bajo el control de este último. Por defecto, cada 5 min. O en bases temporales configuradas, el ESP32 envía un comando para la recolección y registro de los datos. De manera simultánea, se obtienen los datos provenientes del piranómetro y se ajusta la velocidad del ventilador. Tras completar este procedimiento, los datos son transmitidos al servidor para su posterior visualización en la página web, repitiéndose este ciclo cada 5 min.



(b) Tarjeta madre del adquisidor de datos

Figura 4.4: Sistema de adquisición de datos

4.1.3.1. Descripción de los sensores

Cada una de las etapas antes mencionadas del adquisidor de datos está equipada con diferentes sensores y actuadores, todas las etapas están comunicadas entre sí por el protocolo de comunicación digital RS-485, el cual es un estándar de comunicaciones muy utilizado en aplicaciones de adquisición y control de datos, desempeñando un papel crucial en el control industrial y la instrumentación, esto a causa de su soporte de 32 dispositivos por el mismo bus, su alcance de 1200m y su gran tolerancia al ruido, haciéndolo ideal para aplicaciones industriales [65]. La primera etapa consta de 4 sensores de la marca Sensirion (Marca registrada 1998 Stäfa, Suiza [66]) modelo SHT40I-AD1F (Figura 4.5) cuyas características se muestran en la siguiente Tabla 4.3

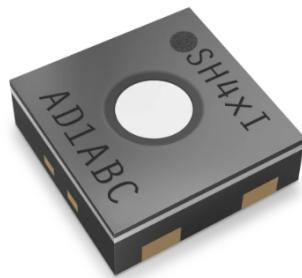


Figura 4.5: Sensor Sensirion SHT4X

Especificaciones			
Humedad	Precisión típica	2	%RH
	Rango operativo	0 a 100	
Temperatura	Tiempo de respuesta	4	s
	Precisión típica	0.2	°C
Electrónicas	Rango operativo	-40 a 125	
	Tiempo de respuesta	2	s
Voltaje de alimentación		2.3 a 5.5	V
Corriente de funcionamiento		21	uA
Interfaz		I^2C	

Tabla 4.3: Especificaciones SHT40I-AD1F [67]

Para la etapa encargada de adquisición de pesos se utilizaron galgas extensiométricas TAL220 de 5Kg (Figura 4.6) de la marca HT Sensor Technology CO,. Limited (Marca registrada 2015 Zhejiang, China [68]) acompañadas del convertidor analógico-digital (ADC) de 24 bits HX711

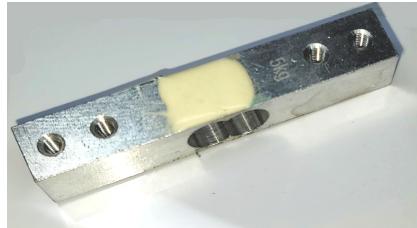


Figura 4.6: Galga extensiométrica de 5Kg

la cual cuenta con las siguientes características Tabla 4.4

Especificaciones

Material	Aleación de aluminio
Tipo	Viga paralela
Resistencia de entrada	1000 ± 15 Ω
Resistencia de salida	1000 ± 10
Rango operativo de temperatura	-10 a +55 $^{\circ}\text{C}$

Tabla 4.4: Características galga extensiométrica [69]

Para la última etapa, se adquiere la irradiancia solar por medio de un piranómetro modelo CMP6 Clase B marca Kipp & Zonen (Marca registrada 1830 Utrecht, Países Bajos [70]) (Figura 4.7) con las características mostradas en la Tabla 4.5.



Figura 4.7: piranómetro CMP6

Especificaciones					
Rango espectral	285 a 2800	nm			
Sensibilidad	5 a 20	$\mu V/W/m^2$			
Tiempo de respuesta	12	s			
Máxima irradiación solar	2000	W/m^2			
Campo de visión	180	$^\circ$			

Tabla 4.5: Características piranómetro CMP6 [71]

La cual es recolectada por el microcontrolador ESP32 diseñado por Espressif Systems (Marca registrada 2008 Shanghai, China [72]), el cual, adicional a esto, se encarga de controlar la velocidad del ventilador mediante PWM (modulación por ancho de pulsos), recolecta la información de las etapas anteriores (Temperatura, Humedad relativa y pesos) mediante protocolo RS-485 para posteriormente enviar los datos a un servidor web utilizando la conexión Wi-Fi para su visualización (Figura 4.8). Todo este proceso es representado en la Figura 4.4a.

ID	Nombre	Propietario	Fecha	Estado	
137	Manzana Canatlán	Dago	2024-10-24	Terminado	Ver datos
136	Carne Seca	Dago	2024-10-24	Terminado	Ver datos
135	Plátano	Dago	2024-10-14	Terminado	Ver datos
134	Carne seca 2	Dr. Erick	2024-10-02	Terminado	Ver datos
133	Carne seca	Dr. Erick	2024-09-26	Terminado	Ver datos
132	Carne seca	Mtro. Jorge	2024-09-24	Terminado	Ver datos
131	Prueba piranómetro	Dago	2024-09-24	Terminado	Ver datos
130	Cáscara naranja v2	Dra. Adriana	2024-08-28	Terminado	Ver datos
129	Prueba Sistema 2	Dago	2024-08-28	Terminado	Ver datos
128	Uva globo rojo	Dago	2024-08-27	Terminado	Ver datos
127	Prueba	Dago	2024-08-21	Terminado	Ver datos
126	Cáscara de naranja 3K	Dra. Adriana	2024-08-14	Terminado	Ver datos
125	Prueba sistema	Dago	2024-08-09	Terminado	Ver datos
124	Secado de uva	Figueroa y Guevara	2024-08-08	Terminado	Ver datos
123	Carne seca	Anael	2024-07-11	Terminado	Ver datos
122	Prueba Chile poblano 1	Dago	2024-07-02	Terminado	Ver datos
121	Prueba Trapos 2	Dago	2024-06-18	Terminado	Ver datos
120	Prueba trapos	Dago	2024-05-30	Terminado	Ver datos
119	Prueba Piranometro V2	Dago	2024-05-29	Terminado	Ver datos

Figura 4.8: Página web alojada en los servidores del CIMAV ([link](#))

4.2. Métodos

4.2.1. Diseño de la arquitectura para una RNA

Para el proceso de predicción, los datos recopilados en el paso previo se emplearán como conjunto de entrenamiento, por tanto, para llevar a cabo esta tarea, el primer paso en todo diseño neuronal corresponde a la selección de entradas y salidas [55]. En este caso, dividimos nuestras entradas y salidas para diseñar dos modelos neuronales, esto para tener un modelo que, en un futuro, pueda usarse como base de un sistema de control, por lo que la distribución de entradas y salidas quedaría de la siguiente manera Tabla 4.6

	Entradas	Salidas
RNA 1	Temperatura ambiente Humedad Relativa ambiente Irradiancia Solar	Temperaturas y humedades dentro de la cámara de secado
RNA 2	Temperatura ambiente Humedad Relativa ambiente Irradiancia Solar Temperatura del aire dentro de la cámara de secado Humedad Relativa dentro de la cámara de secado Peso inicial total Peso inicial en cada báscula Producto	Cinética de secado por cada báscula

Tabla 4.6: Entradas y salidas del modelo neuronal

Para el diseño de la arquitectura de la red neuronal, se realizó de dos maneras, la primera mediante un análisis paramétrico, y la segunda utilizando algoritmos evolutivos.

Como primer caso se evaluaron 4 arquitecturas de red: Patternnet, Feedforwardnet, Cascadeforwardnet y Fitnet, las cuales se describen a continuación [73, 74, 75, 76].

1. **Patternnet:** Son redes enfocadas al reconocimiento de patrones, son prealimentadas y pueden ser entrenadas para asignar entradas a clases particulares. se caracterizan por los datos objetivo ya que deben consistir en vectores donde todos sus valores sean cero, a excepción de un único elemento, el cual está en la posición i, para denotar la clase que representan.

2. **Feedforwardnet:** Se componen de múltiples capas, donde la capa inicial establece una conexión directa con la entrada de la red. Cada capa subsiguiente se enlaza con la que la precede, hasta que las capas finales producen la salida de la red. Estas redes son versátiles, apropiándose de cualquier aplicación que necesite una relación de entrada a salida definida. Una red feedforward que incorpora una capa intermedia junto con una cantidad adecuada de neuronas en las capas ocultas puede adaptarse a cualquier problema que requiera la correspondencia entre entradas y salidas de aplicación.
3. **Cascadeforwardnet:** Estas redes muestran similitudes con las redes Feedforwardnet convencionales, pero integran enlaces adicionales desde la entrada y cada una de las capas previas hacia las capas subsecuentes. Una red en cascada compuesta por dos o más capas es capaz de aprender cualquier relación finita entre entrada y salida con elevada precisión, siempre que cuente con un número adecuado de neuronas ocultas.
4. **Fitnet:** Consiste en una red neuronal multicapa clásica caracterizada por la presencia de capas ocultas y una capa de salida lineal, utilizada para tareas de regresión y ajuste de curvas.

Con el mismo conjunto de datos y los mismos parámetros, únicamente variando la arquitectura, mismas que fueron evaluadas y se mantuvieron las que presentaron un mejor rendimiento para seguir con las siguientes etapas.

4.2.2. EV del rendimiento de la RNA

Se evaluó la cercanía entre los valores obtenidos reales y las proyecciones del modelo mediante el coeficiente de determinación (R^2) (Ec. 4.1), el error cuadrático medio (RMSE) (Ec. 4.2) y el error absoluto medio porcentual (MAPE) (Ec. 4.3), que se utilizan habitualmente en aplicaciones de aprendizaje automático [77, 78].

$$R^2 = \frac{SCR}{SCT} = 1 - \frac{SCE}{SCT} \quad (4.1)$$

donde:

- SCE es la suma de cuadrados de error
- SCR es la suma de cuadrados de regresión

- SCT es la suma de cuadrados total

$$RMSE = \sqrt{\sum_{i=0}^n \frac{(y_i - \hat{y}_i)^2}{n}} \quad (4.2)$$

$$MAPE = \sum_{i=1}^n \frac{|y_i - \hat{y}_i|}{y_i} \times 100\% \quad (4.3)$$

donde:

- \hat{y}_i son los valores predichos
- y_i son los valores reales
- n es el número de valores

4.2.3. Análisis paramétrico

El análisis paramétrico se dividió en dos secciones:

1. Selección de la función de entrenamiento
2. Selección del numero de capas ocultas y neuronas por capa

4.2.3.1. Selección de la función de entrenamiento

Para la selección de la función de entrenamiento se desarrolló un código en MATLAB (1984 Natick, Massachusetts [79]) que, mediante 100 entrenamientos con cada función de entrenamiento disponible en MATLAB (Tabla 4.8) y variando el número de neuronas en una sola capa, por lo que por cada función de entrenamiento se tenían 100 entrenamientos, dando un total de 1200 entrenamientos, esto para evaluar de manera robusta el desempeño de cada función de entrenamiento, considerando un número significativo de muestras (100 entrenamientos por función) para reducir la variabilidad y asegurar que los resultados sean representativos y fiables. Este proceso se repitió con las arquitecturas seleccionadas del paso anterior, en las cuales la proximidad entre los valores medidos reales y las estimaciones del modelo fueron evaluadas utilizando el error absoluto medio porcentual (MAPE) (Ec. 4.3), la configuración del proceso de selección se presenta en la Tabla 4.7.

Numero de entrenamientos	1200
Funciones de entrenamiento	12
Método de evaluación del desempeño	MAPE
Capas ocultas	1
Neuronas por capa	1-100

Tabla 4.7: Selección de función de entrenamiento

Función de entrenamiento	Algoritmo
'trainlm'	Levenberg-Marquardt
'trainbr'	Regularización bayesiana
'trainbfg'	BFGS quasi-Newton
'trainrp'	Retropropagación resiliente
'trainscg'	Gradiente conjugado escalado
'traincgb'	Gradiente conjugado con reinicios de Powell/Beale
'traincfg'	Gradiente conjugado de Fletcher-Powell
'traincgp'	Gradiente conjugado de Polak-Ribière
'trainoss'	Secante de un paso
'traingdx'	Gradiente descendente de tasa de aprendizaje variable
'traingdm'	Gradiente descendente con momento
'traingd'	Gradiente descendente

Tabla 4.8: Funciones de entrenamiento MATLAB [80]

4.2.3.2. Selección del número de capas ocultas y neuronas por capa

En esta sección se desarrollara en MATLAB un programa el cual, de manera iterativa, aumenta el número de neuronas en cada capa y el número de capas ocultas, configurado con la función de entrenamiento y arquitectura que presentó un mejor rendimiento. Para, posteriormente, guardar en un archivo .csv el error, el número de capas ocultas y el número de neuronas por capa para su posterior análisis.

4.2.4. Algoritmo Genético

Como se mencionó anteriormente, los algoritmos genéticos al ser implementados como métodos computacionales son enfocados a la optimización y han sido empleados para la elec-

ción y diseño de arquitecturas de redes neuronales [61, 62] por ese motivo es que se utilizará un AG básico para la selección de la arquitectura y de los pesos iniciales, por lo cual se desarrollaron dos códigos, el primero para la selección del número de capas ocultas y neuronas por capa y el segundo para la selección de los pesos iniciales.

Para ambos casos el proceso del AG es representado en la Figura 4.9 donde para el caso de nuestro primer código la población corresponde a un número de capas ocultas y neuronas para cada capa oculta y para el segundo la población representa los pesos iniciales de la red neuronal.

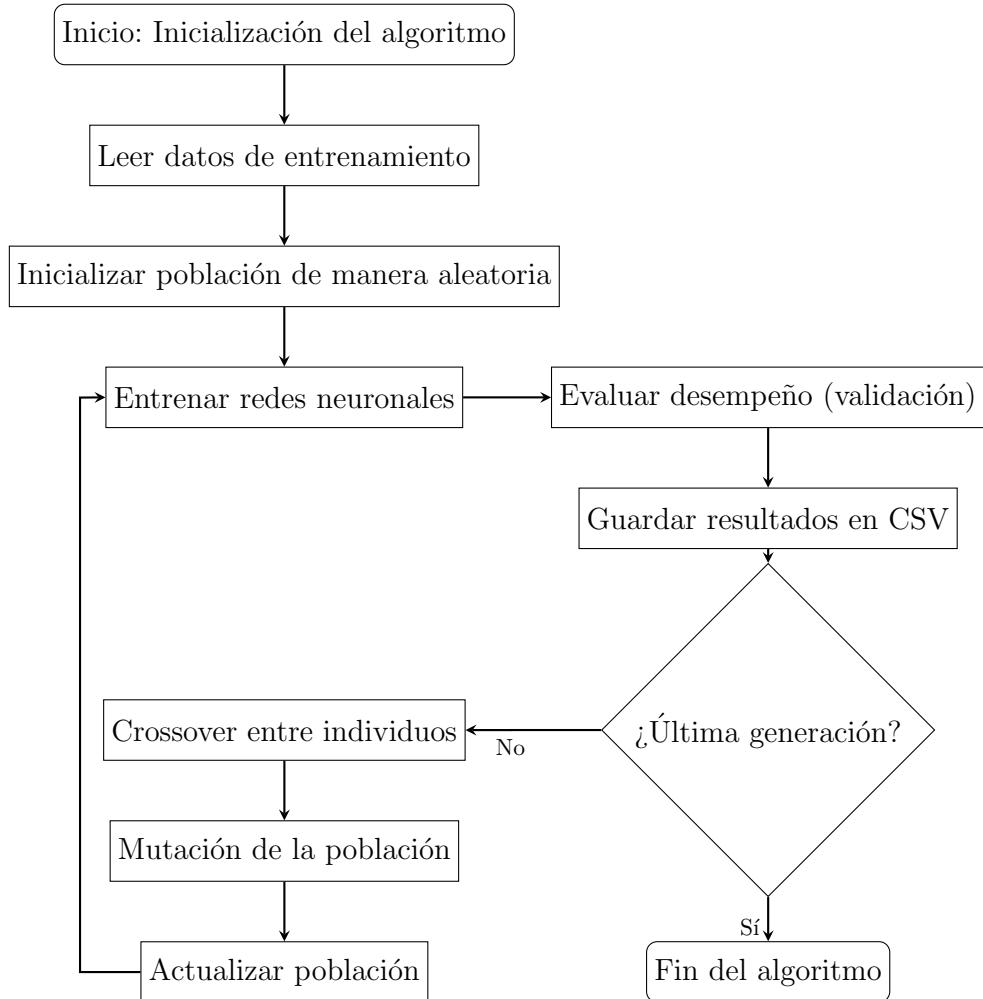


Figura 4.9: Diagrama de flujo del algoritmo evolutivo para selección de arquitectura

En este capítulo, se ha expuesto con detalle la metodología implementada para abordar los objetivos de la tesis en cuestión. En el capítulo siguiente, se presentarán y analizarán los resultados obtenidos en relación con los objetivos planteados.

CAPÍTULO 5

RESULTADOS

En el presente capítulo se exponen los resultados alcanzados a lo largo del desarrollo de la investigación, sustentados en los datos recopilados y analizados mediante las metodologías descritas previamente.

5.1. Datos de secado

Se obtuvo la cinética de secado y su contenido de humedad, mostrado en la Tabla 5.1.

Alimento	Contenido de Humedad %	
	Inicial	Final
Manzana Canatlán	81.38 ±0.1	13.10 ±0.1
Limón agrio sin semilla	76.48 ±0.1	10.76 ±0.1
Plátano Chiapas	52.06 ±0.1	0.63 ±0.1
Uva globo rojo	82.1 ±0.1	6.91 ±0.1
Pulpa bola de res	64.47 ±0.1	2.10 ±0.1
Chile poblano	84.27 ±0.1	1.61 ±0.1
Casca de naranja	68.48 ±0.1	7.22 ±0.1

Tabla 5.1: Alimentos deshidratados

En la Figura 5.1, se ilustra la variación de la humedad libre en diferentes alimentos a lo largo del tiempo. En alimentos como la carne de res (Figura 5.1e), la manzana de Canatlán (Figura 5.1a) y el limón agrio (Figura 5.1b), se detectó una disminución significativa de la humedad durante las dos primeras horas. Por el contrario, productos como la uva globo rojo (Figura 5.1d) y el chile poblano (Figura 5.1f) requirieron un periodo más prolongado en su proceso de secado. Aunque la humedad libre inicial es distinta entre todos los tratamientos, se puede apreciar que la curva de secado de la manzana de Canatlán (Figura 5.1a) guarda similitudes con la del limón agrio (Figura 5.1b). El equilibrio de humedad de una muestra, a una temperatura y humedad del aire determinadas, se alcanza cuando el contenido de humedad del material no presenta cambios apreciables con el tiempo de procesamiento. Esto se logró en algunos alimentos como la uva globo rojo (Figura 5.1d), mientras que en otros, como el limón agrio (Figura 5.1b), no se alcanzó tal estado. Las cinéticas de secado mencionadas se llevaron a cabo como parte del proceso de entrenamiento de la red neuronal. No obstante, en la Figura 5.1, únicamente se ilustran las cinéticas correspondientes a una balanza y a una sola prueba para aquellos alimentos que fueron sujetos a pruebas repetidas. Asimismo, los alimentos como la uva globo rojo (Figura 5.1d) y el chile poblano (Figura 5.1f) experimentaron dificultades en la adquisición de datos debido a interrupciones en la conexión wifi, lo que dio lugar a caídas abruptas en el registro de peso.

A continuación se presentan las cinéticas de secado de cada producto evaluado:

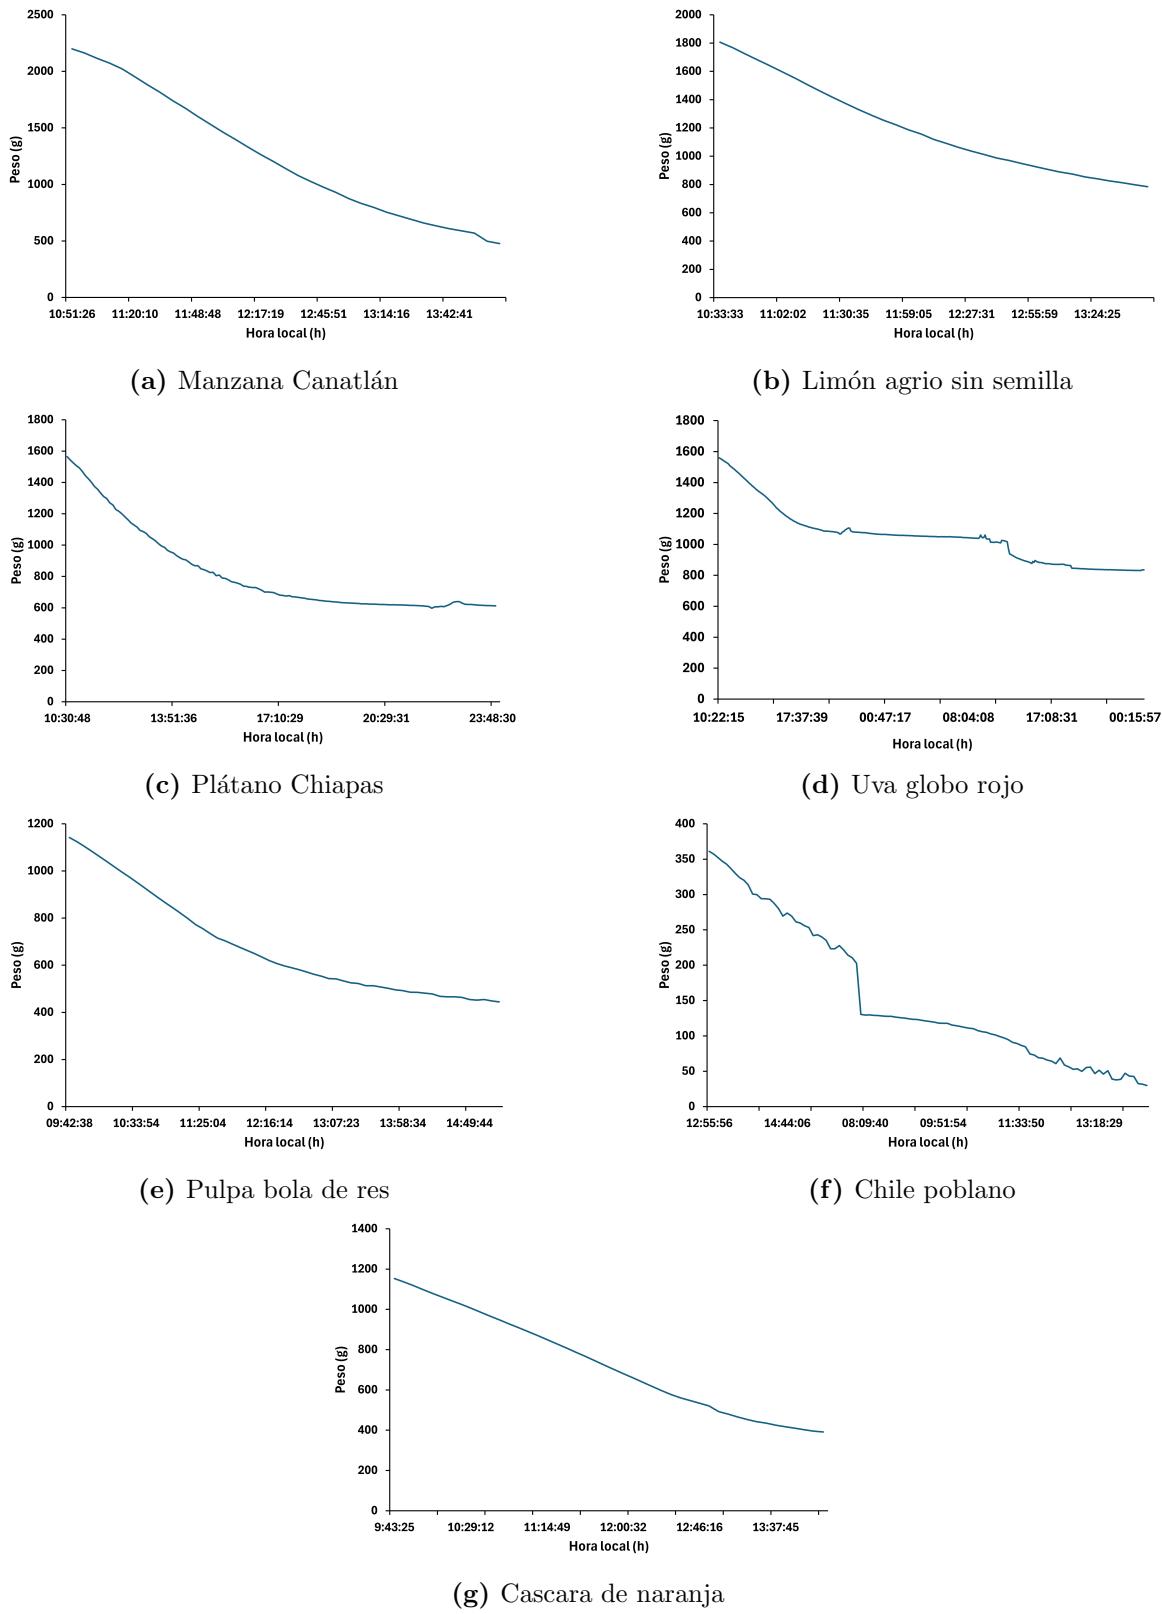


Figura 5.1: Cinéticas de secado derivadas del proceso de deshidratación de los alimentos

5.2. Elección de la arquitectura

5.2.1. Análisis paramétrico

El análisis paramétrico se desarrolló únicamente para la RNA 1 (Tabla 4.6). Dicho análisis se realizó con la siguiente configuración (Tabla 5.2); adicionalmente, utilizando 1000 épocas como constante, que es el valor predeterminado proporcionado por MATLAB y configurada como red neuronal de tipo cascadeforwardnet, prealimentada en cascada, esto se determinó a partir de pruebas experimentales donde su desempeño superó al de otras configuraciones, como Feedforwardnet [75].

Variables	Rango
Capas ocultas	1 a 5
Neuronas por capa	1 a 10

Tabla 5.2: Configuración para el análisis paramétrico

Teniendo un total de $10^5 = 100,000$ combinaciones de las cuales solo se realizaron 55,574 debido a que el algoritmo evolutivo encontró una arquitectura más rápido que este método, por lo que se detuvo este análisis. Todos estos entrenamientos fueron evaluados mediante el error absoluto medio porcentual MAPE (E.c. 4.3) todas las iteraciones con su respectivo error se pueden apreciar en la Figura 5.2

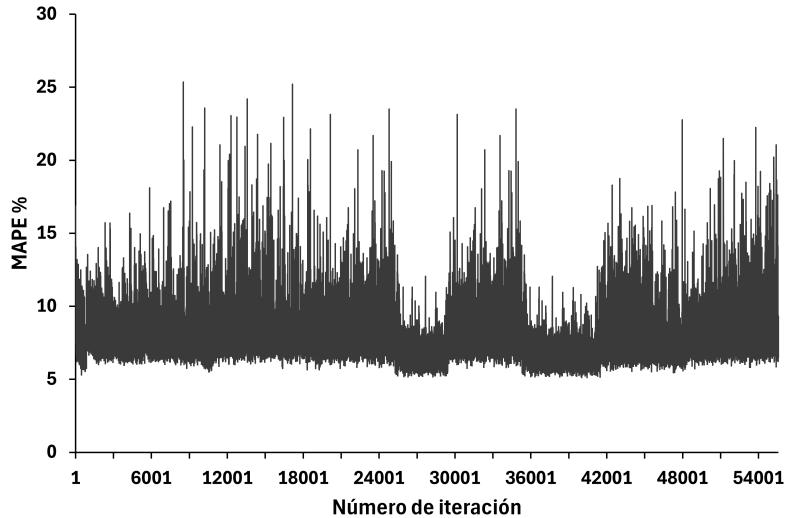


Figura 5.2: Entrenamientos mediante el análisis paramétrico

donde el error máximo obtenido es del 25.3581 % con una arquitectura de 3-4-4-10-3-1-8 y el mínimo de 5.4154 % con una arquitectura de 3-5-4-9-10-2-8 ambos con un total de 3 entradas, 5 capas ocultas y 8 salidas, destacando que ambas arquitecturas derivaron de los entrenamientos realizados durante el análisis paramétrico.

5.2.2. Algoritmo evolutivo

El algoritmo evolutivo utilizado se describe en la Figura 4.9, utilizando el elitismo entre individuos para la reproducción se realizaron 8,066 entrenamientos para el desarrollo de la RNA 1 y 5,475 para el entrenamiento de la RNA 2, ambas con la configuración mostrada en la Tabla 5.3.

Variables	Rango
Capas ocultas	1 a 10
Neuronas por capa	1 a 20
Generaciones	50
Tamaño de población	35
Tasa de cruce	0.7
Tasa de mutación	0.1

Tabla 5.3: Configuración para el algoritmo evolutivo

5.2.2.1. Selección de la RNA 1

Los resultados para la RNA 1 se muestran a continuación en la Figura 5.3 en los cuales se obtuvo un error máximo de 30.76 % con una arquitectura de 3-8-4-9-1-8 con 4 capas ocultas y un error mínimo de 4.97 % con una arquitectura de 3-4-7-7-3-3-8 con 5 capas ocultas (Figura 5.6) siendo esta la arquitectura utilizada para la RNA 1.

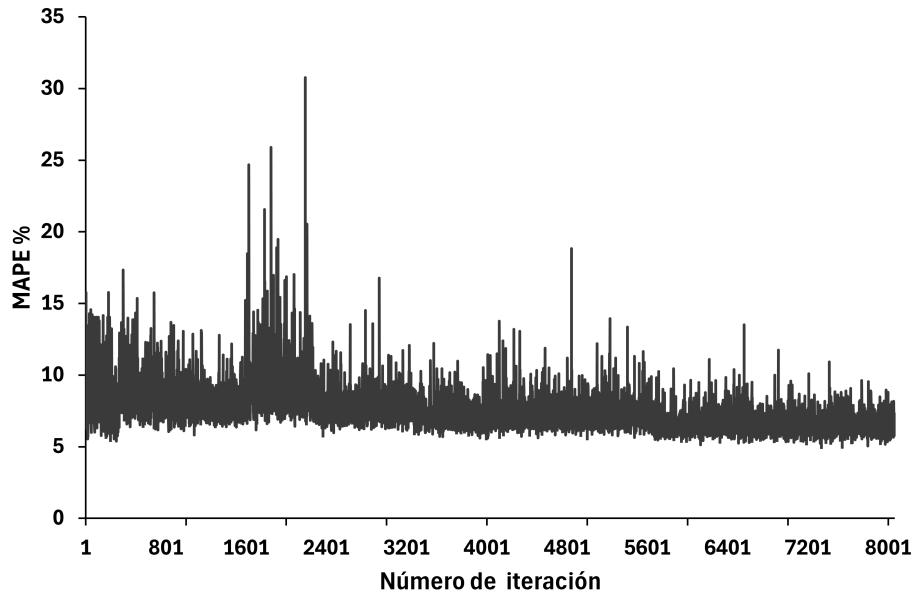


Figura 5.3: Entrenamiento mediante AG RNA 1

Como lo demuestran los experimentos de Thimm y Fiesler (1995), la inicialización de los pesos en una red neuronal es crucial para lograr una rápida convergencia en las redes neuronales de tipo MLP [62]. Por lo tanto, posteriormente, utilizando la arquitectura 3-4-7-7-3-3-8 que presentó un error de 4.97 %, se realizaron 2,400 entrenamientos adicionales con el propósito de seleccionar los pesos iniciales. Estos entrenamientos derivan de la configuración de un algoritmo evolutivo que comprende 60 generaciones con una población de 40 individuos, con el objetivo de disminuir el error aún más y facilitar una convergencia más rápida, logrando un MAPE de 4.64 % con un R^2 de 0.9939, como se ilustra en la Figura 5.4c.

R^2 evalúa la exactitud con la que las predicciones generadas por el modelo se alinean con los datos reales o esperados. Un valor cercano a 1 sugiere que el modelo captura de manera significativa la variabilidad de los datos, mientras que un valor que se aproxima a 0 indica que su capacidad de explicación de dicha variabilidad es mínima. En la Figura 5.4 se ilustra la relación entre los valores pronosticados por la red neuronal y los valores observados, tanto para el conjunto de datos utilizados en el entrenamiento 5.4a como para aquellos empleados en la prueba Figura 5.4b, demostrando cómo las predicciones del modelo se ajustan a los valores reales. En dicha representación se observa un ajuste notable para el conjunto de entrenamiento, con un valor de $R^2_{train} = 0.9965$ que puede interpretarse como el modelo explicando el 99.65 % de la variabilidad de los datos de entrenamiento, lo que evidencia un aprendizaje eficiente de las relaciones dentro de este conjunto. De igual manera, el modelo explica el 97.93 % de la variabilidad en el conjunto de datos de prueba $R^2_{test} = 0.97929$, lo

que indica su capacidad para generalizar a datos inéditos durante el entrenamiento. Además, la diferencia entre ambos valores de R^2 es mínima (0.01721), lo cual sugiere que el modelo no ha incurrido en un sobreajuste respecto a los datos de entrenamiento y es competente para capturar patrones en datos nuevos con una precisión similar a la alcanzada durante el entrenamiento.

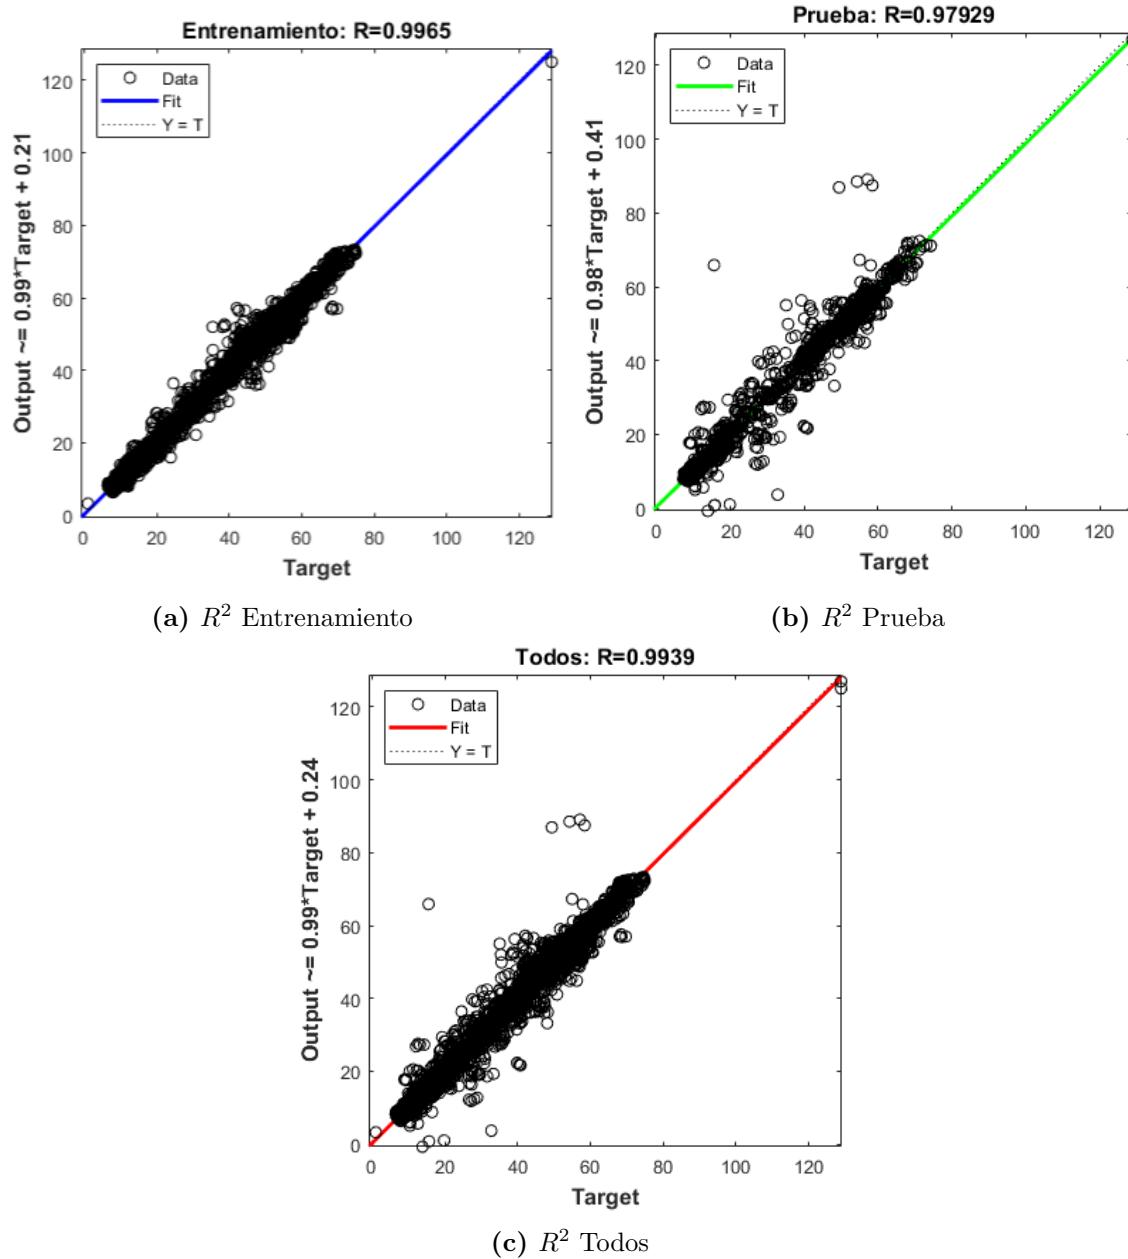


Figura 5.4: R^2 para RNA 1

Mientras que en la Figura 5.5 se muestra la distribución de los errores de predicción, las diferencias entre los valores predichos y los valores reales, al tener los errores alrededor del cero, indican que los errores son aleatorios y no se tiene un sesgo sistemático en las predicciones.

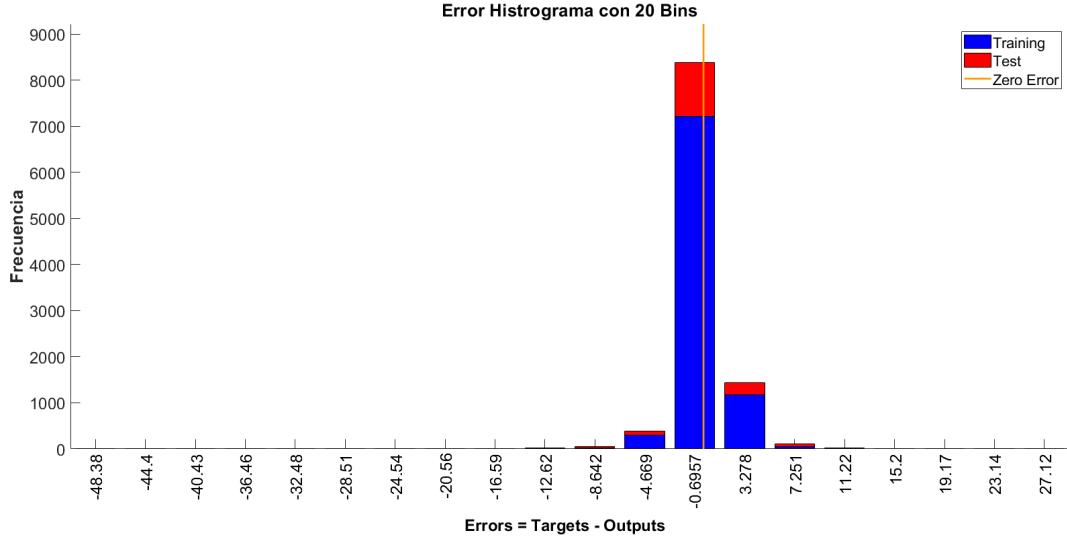


Figura 5.5: Histograma

La arquitectura resultante se organiza de la siguiente manera 3-5-4-9-10-2-8 una capa de entrada con 3 unidades, cinco capas ocultas, y una capa de salida con 8 unidades. Esta estructura se visualiza en la Figura 5.6.

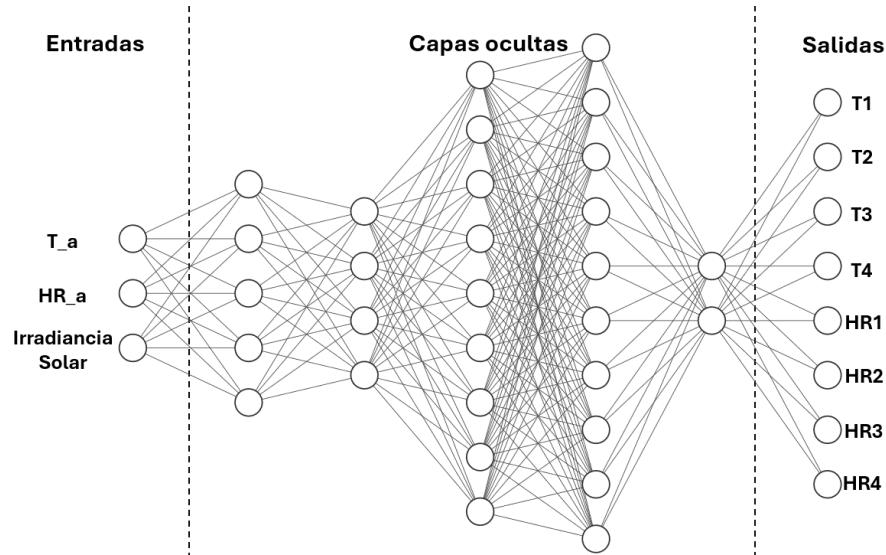


Figura 5.6: Arquitectura RNA 1

5.2.2.2. Selección de la RNA 2

Los resultados para la RNA 2 se muestran a continuación en la Figura 5.7 en los cuales se obtuvo un error máximo de 9.49 % con una arquitectura de 17-1-3 con 1 capa oculta y un error mínimo de 0.67 % con una arquitectura de 17-6-6-3-3 con 3 capas ocultas, recordando que la RNA 2 tiene como objetivo la predicción del peso en función del tiempo. Se presenta un modelo con un error menor al 1%.

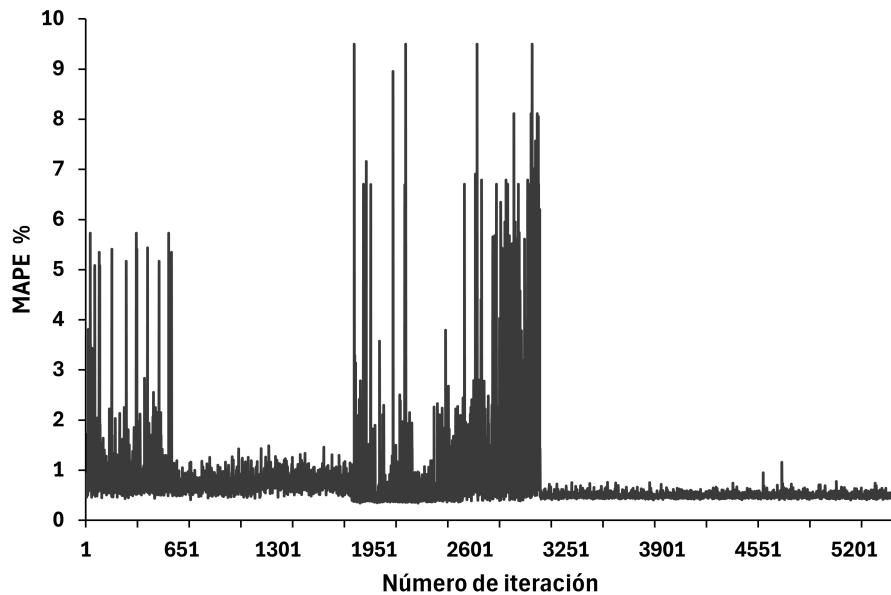


Figura 5.7: Entrenamiento mediante AG RNA 2

Posteriormente se hizo un análisis de sensibilidad o análisis de pesos, el cual implica reducir progresivamente el número de entradas para identificar cuáles son las más relevantes y cuáles podrían ser eliminadas sin afectar significativamente la precisión o la generalización del modelo [81]. Esto con el objetivo de reducir las 17 entradas al mínimo posible sin afectar en gran parte el rendimiento (Figura 5.8).

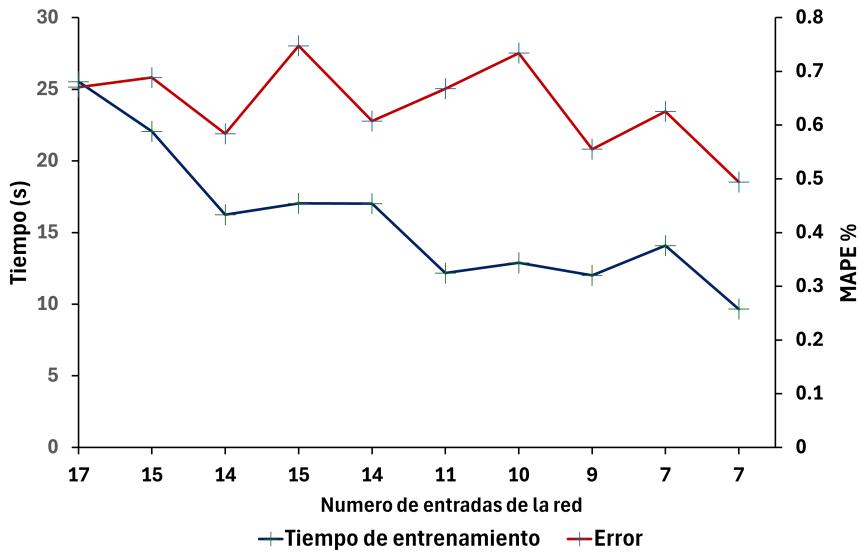


Figura 5.8: Analisis de sensibilidad para RNA 2

Empezando con 17 entradas y quedando únicamente con 7 como se muestra en la Tabla 5.4 y obteniendo con un MAPE de 0.5 %

Entradas iniciales	Entradas Finales
T1, T2, T3, T4	
T_A	T_A
RH1, RH2, RH3 RH4	
RH_A	RH_A
Producto	Producto
Irradiancia Solar	
Tiempo transcurrido	Tiempo transcurrido
Peso Inicial_P1	Peso Inicial_P1
Peso Inicial_P2	Peso Inicial_P2
Peso Inicial_P3	
Peso Inicial Total	Peso Inicial Total

Tabla 5.4: Entradas RNA 2

Finalmente y como se indicó anteriormente, la selección de pesos óptimos es crucial, por lo que se empleó la arquitectura que alcanzó un error de 0.5 % 7-6-6-3-3. De manera análoga a la red previa, se llevaron a cabo 2,400 entrenamientos adicionales, utilizando una configuración del algoritmo evolutivo compuesta por 60 generaciones y 40 individuos. Esto con el objetivo de identificar los pesos iniciales, logrando así reducir el error a 0.49 % y alcanzar un R^2 de 0.9939 Figura 5.9c.

En la Figura 5.9 se muestra la relación entre los valores predichos por la red neuronal y los valores reales, tanto para el conjunto de datos utilizados en el entrenamiento (Figura 5.9a) como para aquellos empleados en la prueba (Figura 5.9b), demostrando cómo las predicciones del modelo se ajustan a los valores reales. Se observa un ajuste excelente para el conjunto de entrenamiento, con un valor de $R^2_{train} = 0.99988$ y para el conjunto de datos de prueba $R^2_{test} = 0.99984$. Ambos valores de R^2 están extremadamente cerca de 1, lo que indica que el modelo explica casi toda la variabilidad de los datos tanto en el conjunto de entrenamiento como en el de prueba. Esto sugiere que el modelo está capturando muy bien las relaciones entre las variables de entrada y la salida.

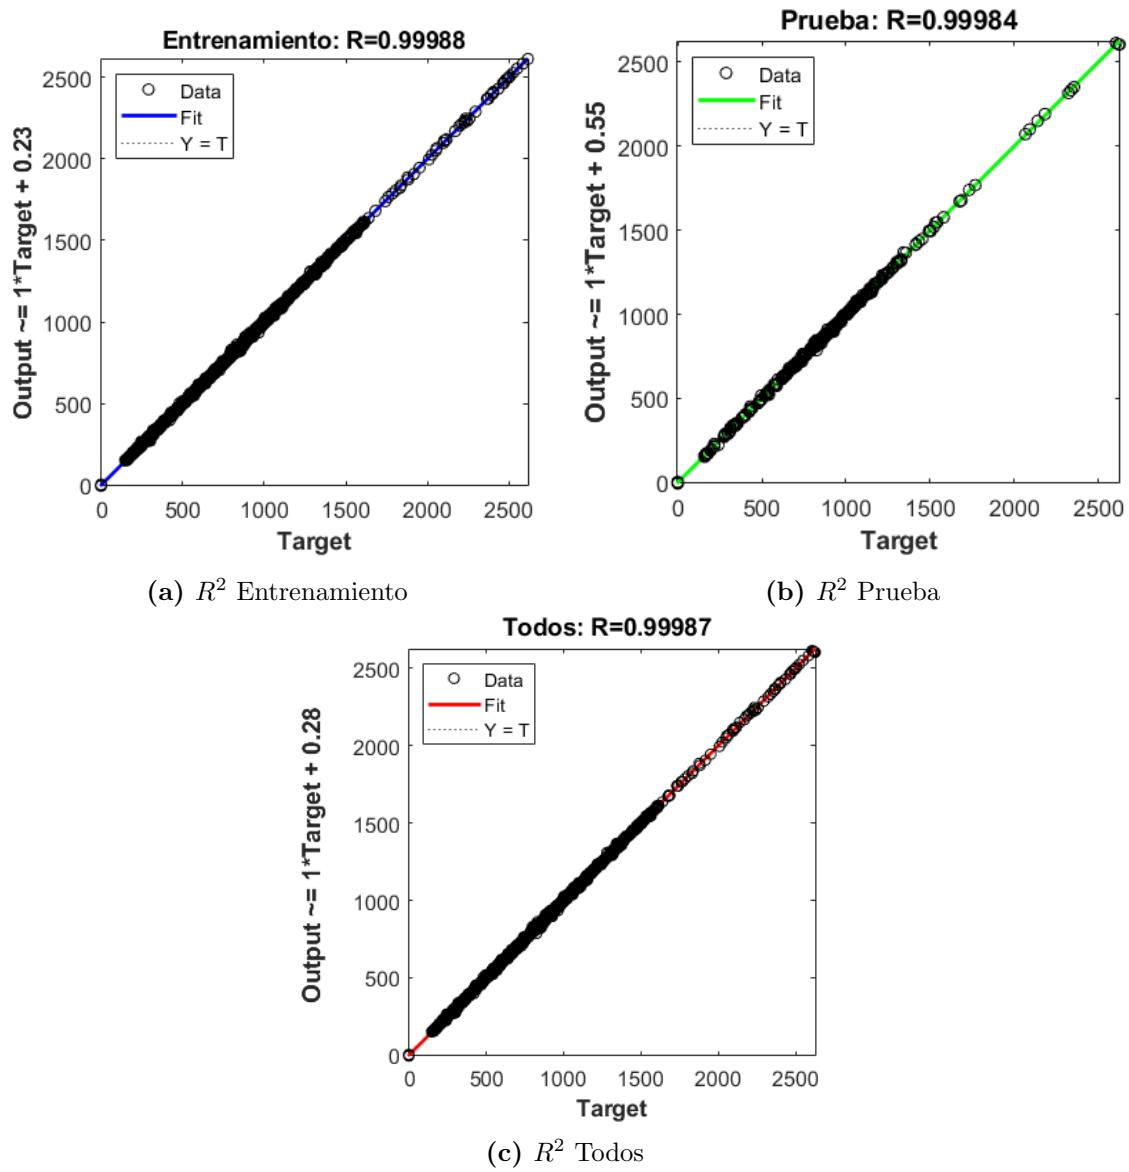


Figura 5.9: R^2 para RNA 2

Mientras que el histograma (Figura 5.10) presenta una forma que se asemeja a una curva de campana (distribución normal), con su pico centrado próximo a 0. Esto sugiere que la mayoría de los errores se encuentran próximos a este valor, indicando que el modelo carece de un sesgo sistemático tanto hacia la sobreestimación como hacia la subestimación, dado que la ocurrencia de errores positivos y negativos es aproximadamente igual.

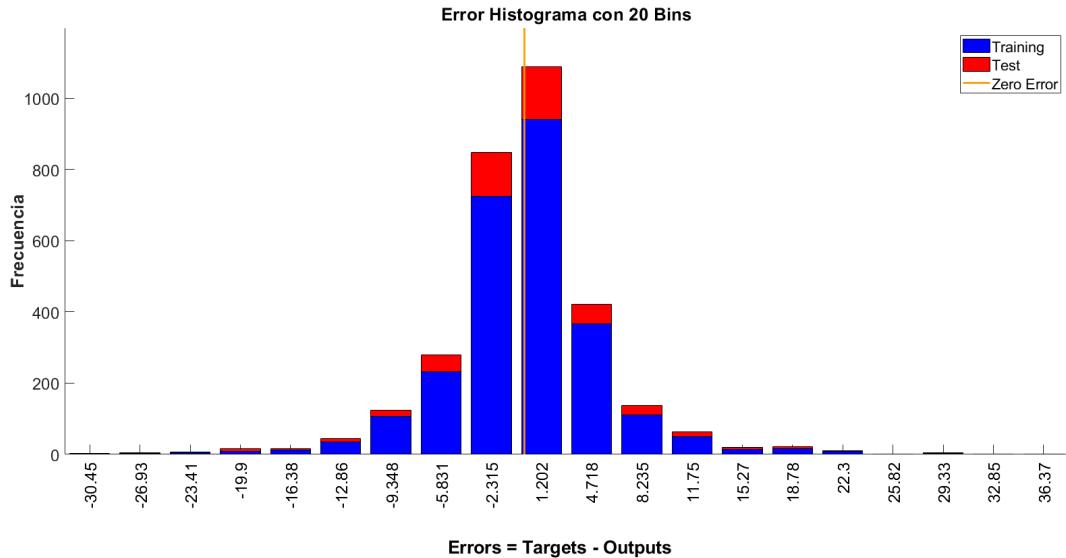


Figura 5.10: Histograma RNA 2

La arquitectura final se organiza de la siguiente manera 7-6-6-3-3, una capa de entrada con 7 unidades, 3 capas ocultas, y una capa de salida con 3 unidades. Esta estructura se visualiza en la Figura 5.11.

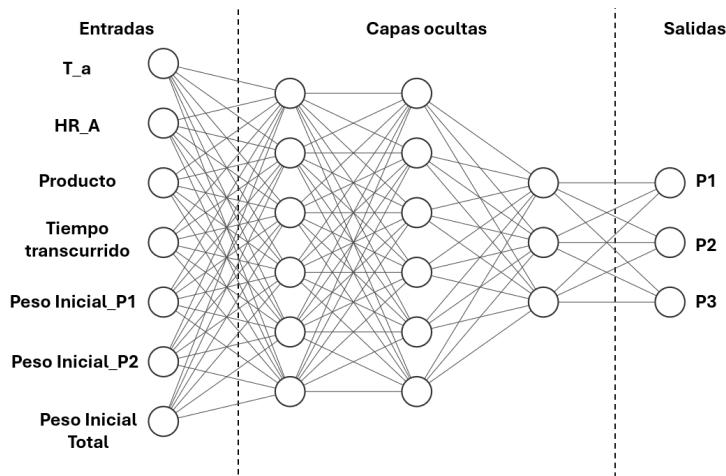


Figura 5.11: Arquitectura RNA 2

5.3. Evaluación del rendimiento

Se evaluó la cercanía entre los valores obtenidos reales y las proyecciones del modelo mediante el coeficiente de determinación (R^2) (Ec. 4.1), el error cuadrático medio ($RMSE$) (Ec. 4.2) y el error absoluto medio porcentual ($MAPE$) (Ec. 4.3), que se utilizan habitualmente en aplicaciones de aprendizaje automático [77, 78]. Esto se llevó a cabo con el propósito de evaluar la calidad del modelo al efectuar predicciones con datos experimentales. Para dicho fin, se realizaron cuatro pruebas experimentales, las cuales se presentan a continuación.

Numero de experimento	Condiciones	Estado
1	Carga de la cámara	Vacio
	Duración	5 días
2	Carga de la cámara	Carne de res
	Duración	5 Horas
3	Carga de la cámara	Carne de res
	Duración	6 Horas
4	Carga de la cámara	Uva globo rojo
	Duración	3 días

Tabla 5.5: Experimentos realizados

5.3.1. Desempeño del modelo RNA 1 en pruebas experimentales

Recordando que la RNA 1 tiene como objetivo predecir las condiciones operativas dentro de la cámara de secado, las cuales son la temperatura y la humedad relativa, se realizaron 2 pruebas experimentales. La primera prueba corresponde al periodo del 10 al 14 de marzo de 2023 con las siguientes condiciones mostradas en la Tabla 5.6

Condiciones	Estado
Carga de la cámara	Vacio
Velocidad promedio del aire dentro de la cámara	1.5 m/s
Flujo volumétrico de agua en los calentadores solares de agua (CSA)	7 L/min

Tabla 5.6: Condiciones experimento 1

Así mismo, las condiciones climáticas durante el experimento se encuentran en la siguiente Figura 5.12a para la temperatura y la humedad relativa y en la Figura 5.12b para la irradiancia solar.

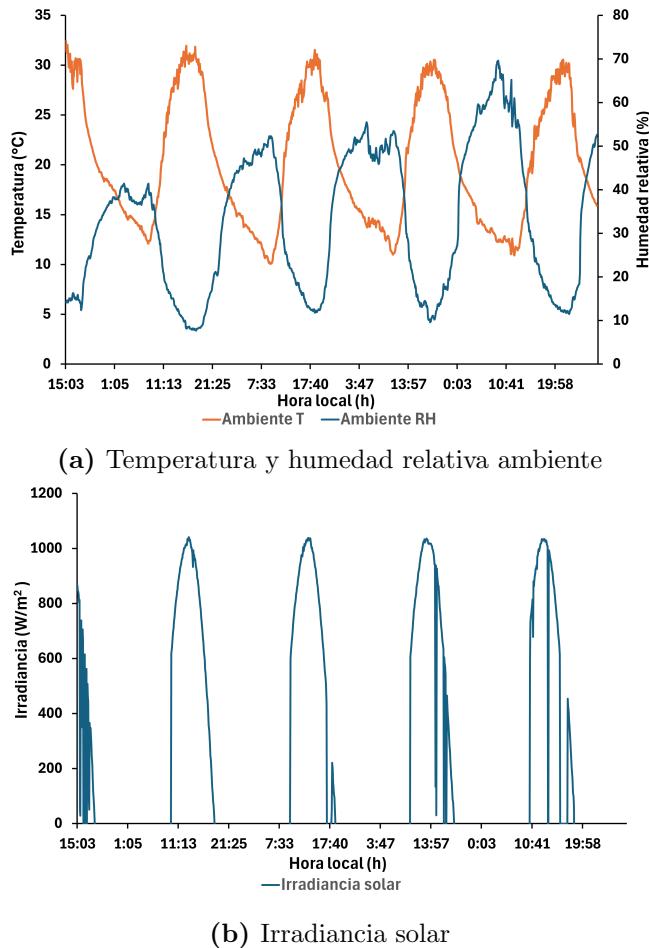


Figura 5.12: Condiciones ambientales experimento 1

Obteniendo los siguientes resultados Tabla 5.7.

Parámetro evaluado	Resultado
R^2	0.9808
RMSE	2.50
MAPE	5.66

Tabla 5.7: Parámetros evaluados experimento 1

Los resultados se presentan en los gráficos a continuación, teniendo en cuenta que las temperaturas y humedades estimadas corresponden a las condiciones presentes en el interior de la cámara de secado, tal como se ilustra en la Figura 4.3.

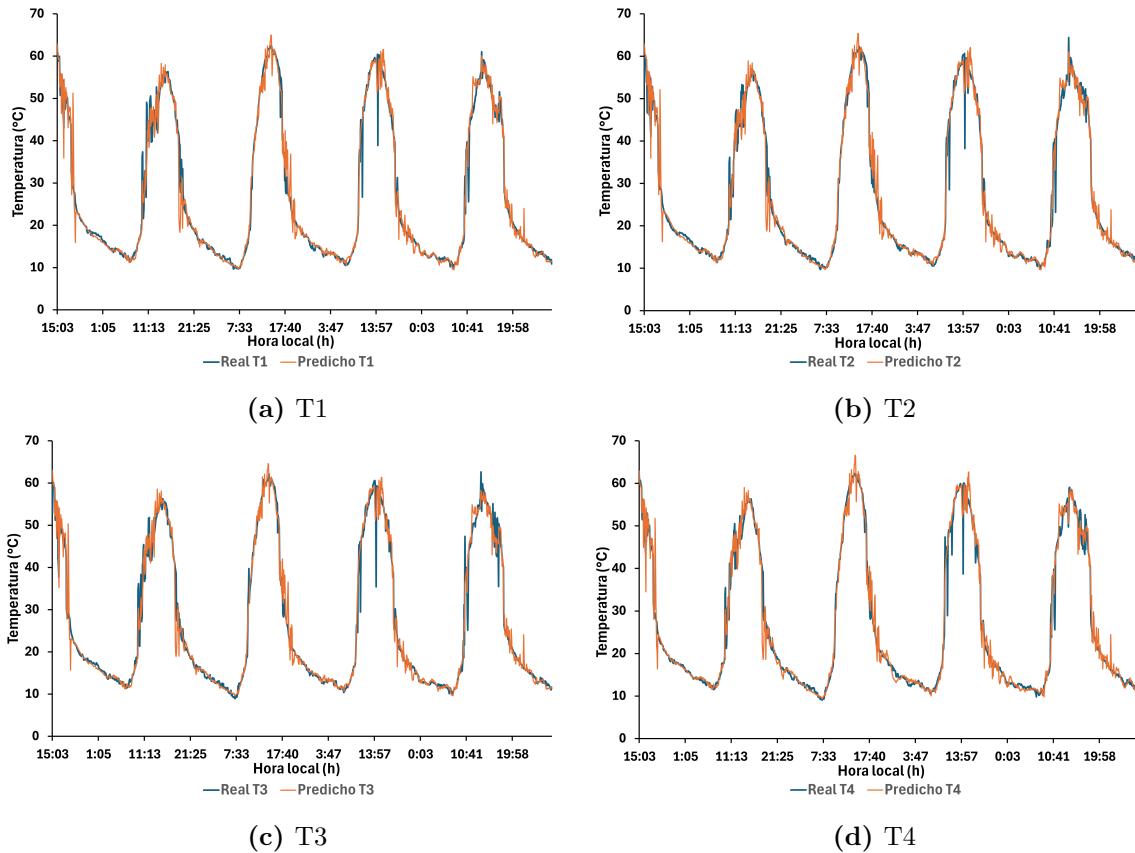


Figura 5.13: Temperaturas dentro de la cámara de secado experimento 1

Demostrando una aproximación considerablemente precisa en comparación con la real, aunque se presentan algunas discrepancias en el caso de la temperatura (Figura 5.13). En lo referente a la humedad relativa, se observan en (Figura 5.14) ciertos picos bajo determinadas condiciones; sin embargo, al igual que en el caso de la temperatura, se alcanza una aproximación bastante exacta con un margen de error inferior al 6 %.

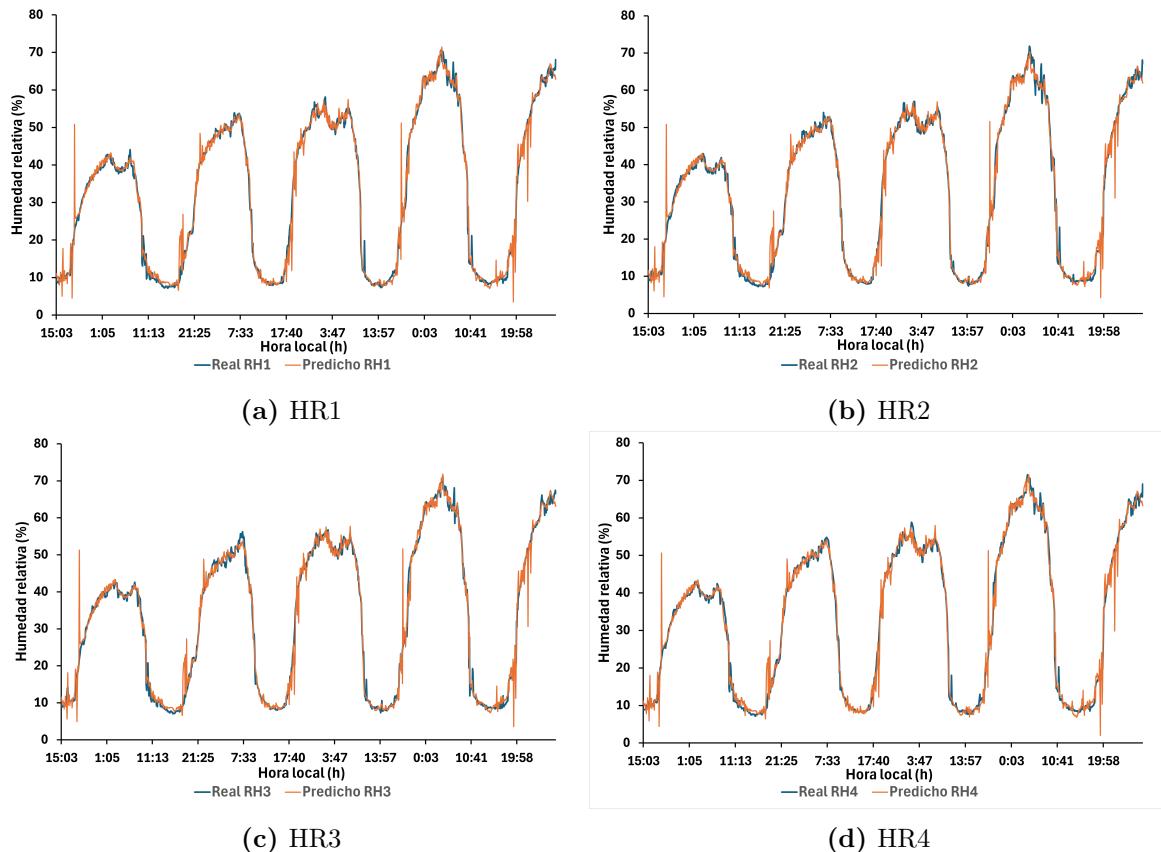


Figura 5.14: Humedad relativa dentro de la cámara de secado experimento 1

Para el experimento número 2 se obtuvieron datos de forma experimental el dia 26 de septiembre de 2024 con las condiciones mostradas en la Tabla 5.8

Condiciones	Estado
Carga de la cámara	Carne de res
Velocidad promedio del aire dentro de la cámara	1.5 m/s
Flujo volumétrico de agua en los calentadores solares de agua (CSA)	7 L/min

Tabla 5.8: Condiciones experimento 2

Así mismo, las condiciones climáticas durante el experimento se encuentran en la siguiente Figura 5.15a para la temperatura y la humedad relativa y en la Figura 5.15b para la irradiancia solar.

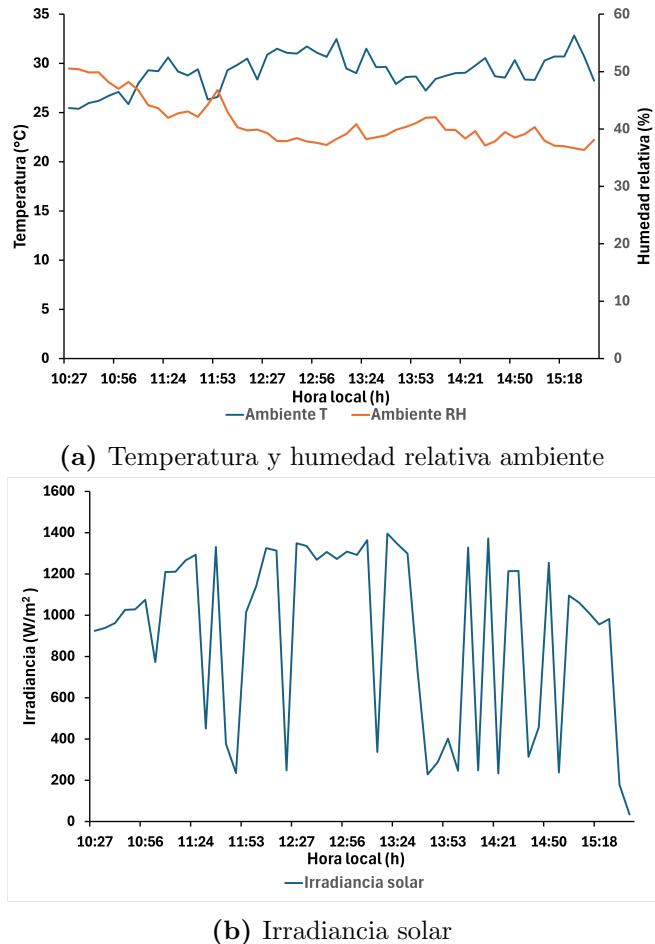


Figura 5.15: Condiciones ambientales experimento 2

Obteniendo los siguientes resultados Tabla 5.9.

Parámetro evaluado	Resultado
R^2	0.7392
RMSE	2.75
MAPE	5.03

Tabla 5.9: Parámetros evaluados experimento 2

Resultados graficados a continuación

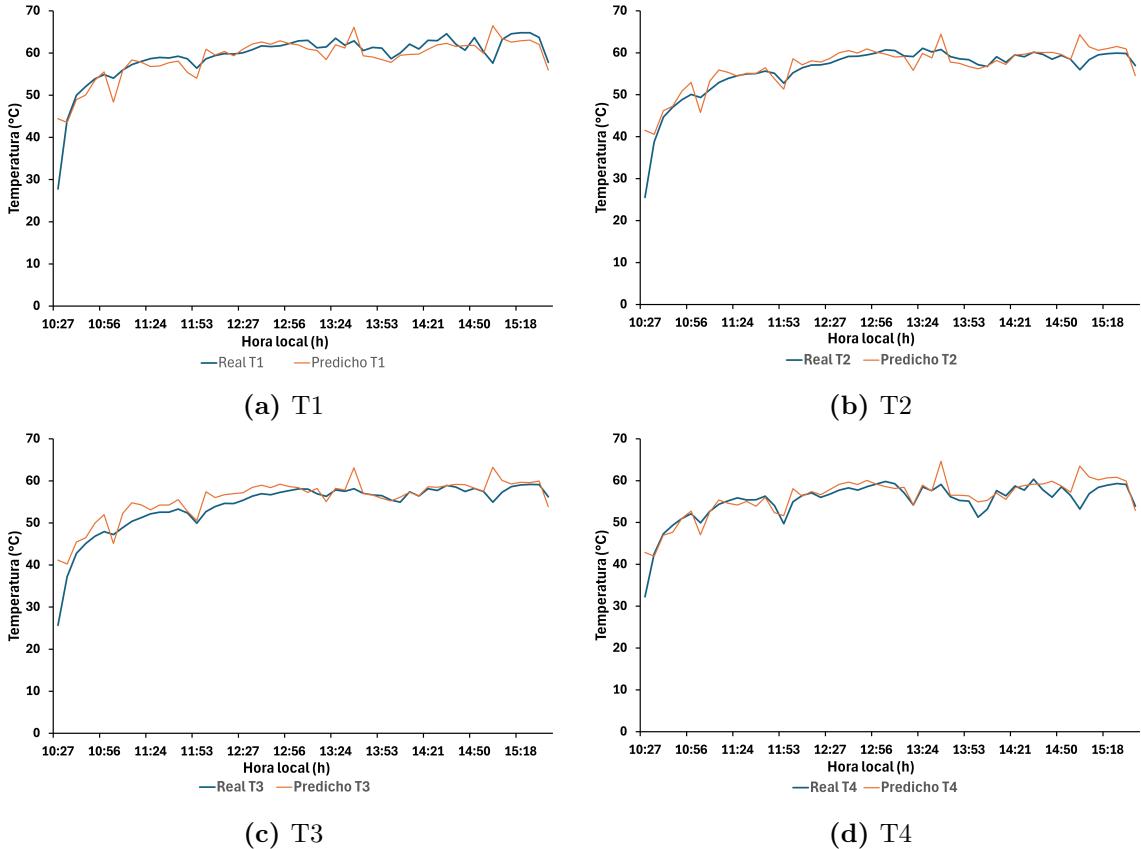


Figura 5.16: Temperaturas dentro de la cámara de secado experimento 2

Al igual que en el experimento anterior, las temperaturas y humedades estimadas corresponden a las condiciones presentes en el interior de la cámara de secado, como se muestra en la Figura 4.3. Los resultados son bastante satisfactorios, ya que se logra un error de menos del 6 %, a pesar de que este experimento se realizó durante un periodo más corto que el anterior. Los valores se aproximan bastante a las condiciones reales tanto de temperatura (Figura 5.16) como de humedad relativa (Figura 5.17) las métricas con las que fue evaluado indican un buen desempeño. ya que el modelo predice temperatura y humedad relativa dentro de la cámara de secado es probable que haya aprendido correlaciones intrínsecas entre ellas, como alguna relación entre la temperatura y la humedad relativa, esto podría indicar que el modelo no solo funciona si no que entiende patrones físicos lo cual podría ser una señal de robustez y suponiendo una mejora frente al modelo presentado por Farhat Mahmood y colaboradores, el cual únicamente predice la temperatura [25]. De la misma manera la elección del modelo y el diseño y configuración de los hiperparametros fue la adecuada para esta aplicación.

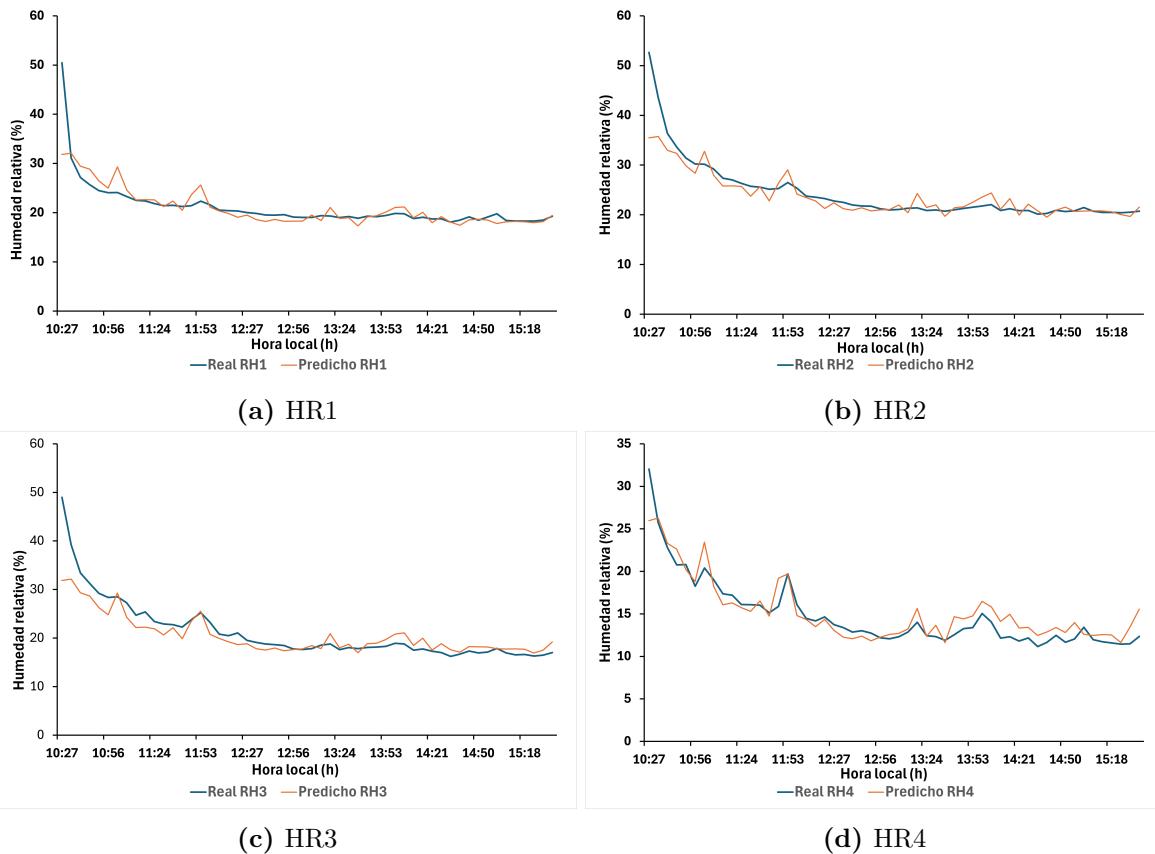


Figura 5.17: Humedad relativa dentro de la cámara de secado experimento 2

5.3.2. Desempeño del modelo RNA 2 en pruebas experimentales

Considerando que el objetivo de la RNA 2 es predecir la pérdida de peso de diversos alimentos en función del tiempo, se llevaron a cabo 2 pruebas experimentales.

El tercer experimento corresponde al 15 de octubre de 2024 con las siguientes condiciones mostradas en la Tabla 5.10, experimento en el cual se optó por secar carne de res.

Condiciones	Estado
Carga de la cámara	Carne de res
Velocidad promedio del aire dentro de la cámara	1.5 m/s
Flujo volumétrico de agua en los calentadores solares de agua (CSA)	7 L/min

Tabla 5.10: Condiciones experimento 3

Así mismo, las condiciones climáticas durante el experimento se encuentran en la siguiente

Figura 5.18a para la temperatura y la humedad relativa y en la Figura 5.18b para la irradiancia solar.

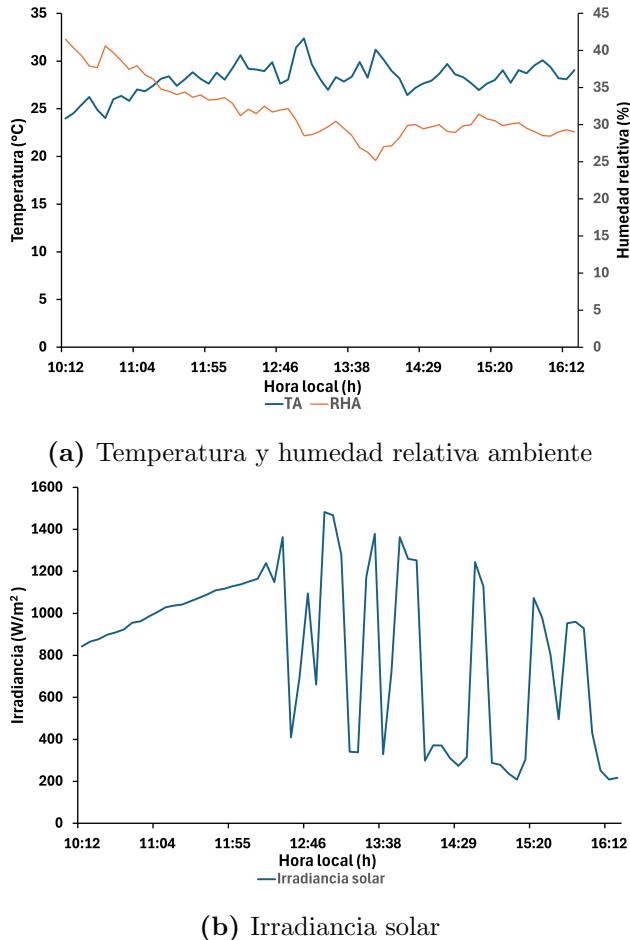


Figura 5.18: Condiciones ambientales experimento 3

Obteniendo los siguientes resultados Tabla 5.11.

Parámetro evaluado	Resultado
R^2	0.9977
RMSE	8.22
MAPE	1.31

Tabla 5.11: Parámetros evaluados experimento 3

Resultados representados a continuación

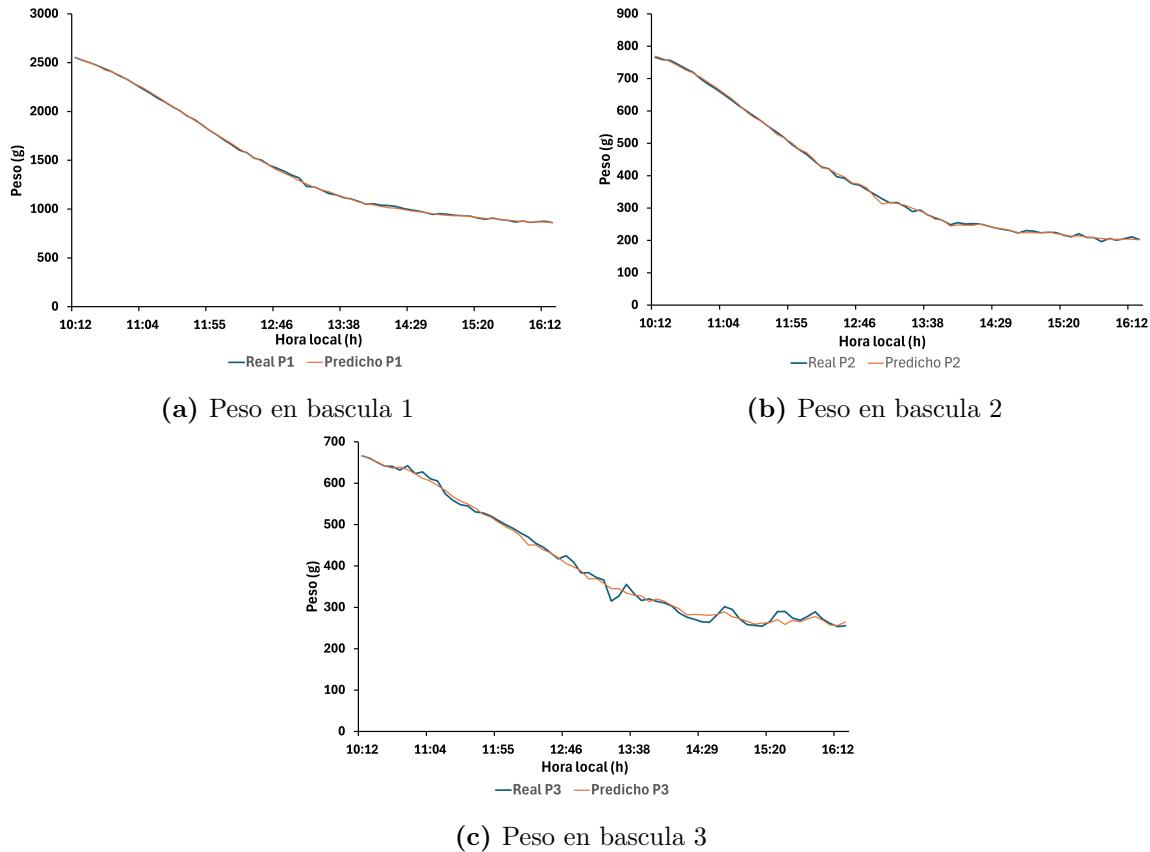


Figura 5.19: Cinéticas de secado experimento 3

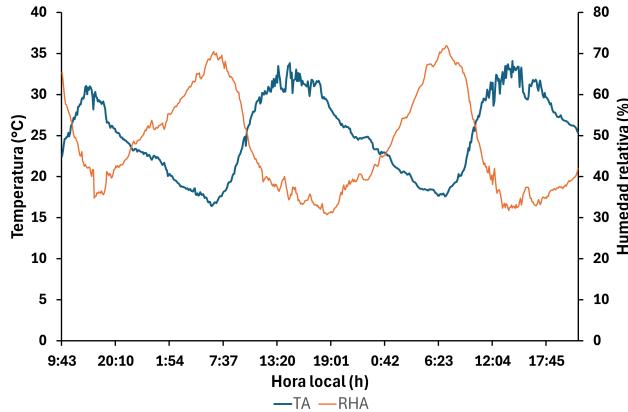
Demostrando una aproximación considerablemente precisa, aunque presentando algunas fallas como se puede observar en la Figura 5.19c, las cuales pueden ser debido al ruido eléctrico del entorno, ruido térmico o interferencias con los mismos componentes del adquisidor de datos por lo cual, tanto lo real como lo predicho presentan ruido en un mayor porcentaje a la báscula 1 y 2, en las cuales es menor, lo que nos afectó tanto el entrenamiento como la predicción en esa báscula, sin embargo se mantiene un error menor al 2 %.

El cuarto experimento corresponde al periodo del 21 al 23 de agosto de 2024 con las siguientes condiciones mostradas en la Tabla 5.12, experimento en el cual se optó por secar uva globo rojo sin semilla.

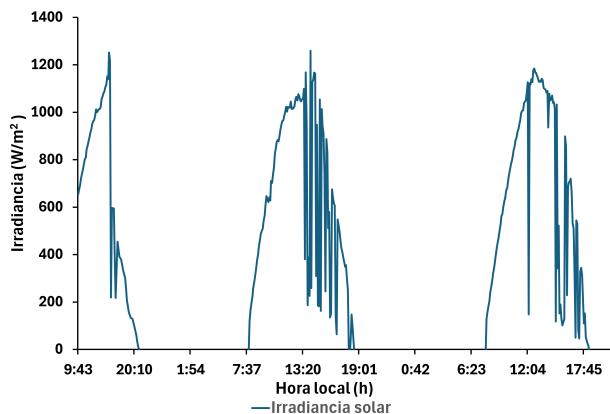
Así mismo, las condiciones climáticas de operación durante el experimento se encuentran en la siguiente Figura 5.20a para la temperatura y la humedad relativa y en la Figura 5.20b para la irradiancia solar.

Condiciones	Estado
Carga de la cámara	Uva globo rojo
Velocidad promedio del aire dentro de la cámara	1.5 m/s
Flujo volumétrico de agua en los calentadores solares de agua (CSA)	7 L/min

Tabla 5.12: Condiciones experimento 4



(a) Temperatura y humedad relativa ambiente



(b) Irradiancia solar

Figura 5.20: Condiciones ambientales experimento 3

Obteniendo los siguientes resultados Tabla 5.13.

Parámetro evaluado	Resultado
R^2	0.9926
RMSE	13.54
MAPE	1.34

Tabla 5.13: Parámetros evaluados experimento 4

Resultados representados a continuación

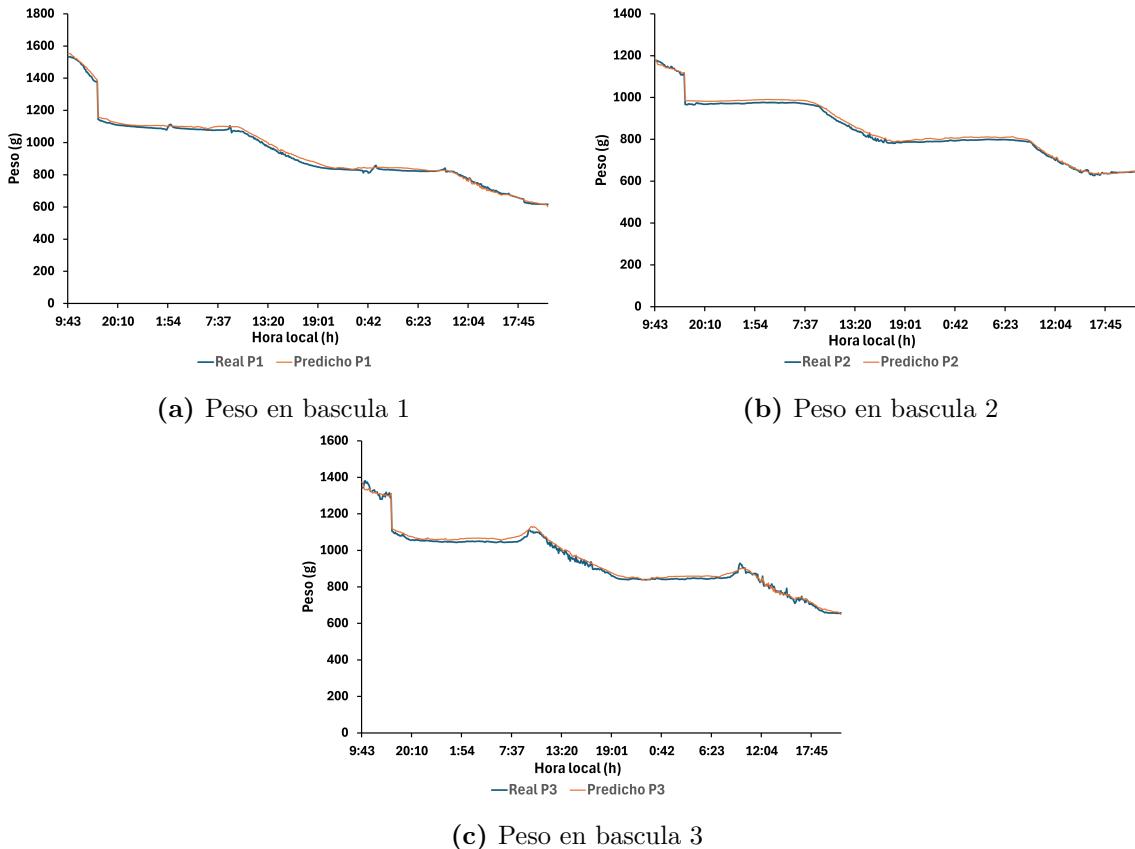


Figura 5.21: Cinéticas de secado experimento 4

Aunque se obtuvo una estimación bastante precisa, durante la duración de este experimento se produjo una interrupción en el servicio de internet. Como se observa en la Figura 5.21, ocurrió una disminución en el peso debido a la pérdida de comunicación con el servidor, resultado del problema de conectividad. A pesar de la pérdida de datos, esto no afecta la evaluación del modelo, manteniéndose un margen de error por debajo del 2 %.

CAPÍTULO 6

CONCLUSIONES

Se recopilaron datos históricos y experimentales a través de 14 experimentos que permitieron la obtención de parámetros operacionales como la temperatura, la humedad relativa interna y ambiental, así como el peso de las muestras en tiempo real, lo que sirvió para generar una base de datos para el entrenamiento del modelo neuronal. Mediante el uso de algoritmos evolutivos se identificó y seleccionó un modelo adecuado para la red neuronal, siendo este el perceptrón multicapa en cascadeforward, el cual demostró un desempeño superior en comparación con otros modelos, obteniendo un MAPE de 4.64 % y un valor de R^2 de 0.99 para la RNA1 (predicción de temperatura y humedad relativa dentro de la cámara de secado), mientras que para la RNA2 (predicción de la cinética de secado) se obtuvo un MAPE de 0.49 % y un valor de R^2 de 0.99. Al validar experimentalmente el modelo, se logró predecir para las condiciones operacionales de la cámara de secado con un margen de error inferior al 6 % y para las predicciones de las cinéticas de secado menos del 2 % , demostrando así ser un modelo adecuado para la estimación de las variables operacionales.

Con el desarrollo de este trabajo se logró demostrar que la implementación de las redes neuronales aplicadas a procesos de secado es una buena herramienta, ya que facilita la planificación del proceso y de la carga, así como las fechas óptimas de secado. Este análisis es aplicable a la cinética de secado, al tiempo que también permite prever la temperatura y

la humedad relativa dentro de la cámara de secado, lo que posibilita determinar por cuánto tiempo se podría mantener una temperatura específica dadas ciertas condiciones ambientales. De igual manera, el modelo RNA 1 puede ser aplicado a un sistema de control inteligente para controlar la temperatura y la humedad relativa en sistemas de secado tecnificados.

6.1. Trabajo Futuro

Desarrollar una base de datos más robusta que abarque una variedad de secadores, incluyendo los de tipo solar, híbrido, convencionales, entre otros, con diversas geometrías, tipo túnel, tipo invernadero, etcétera. Ubicados en diferentes zonas geográficas con el objetivo de comprobar hasta dónde llega la capacidad de generalización de las redes neuronales y confirmar si es posible predecir el comportamiento de un secador en otras ubicaciones geográficas y condiciones climáticas, mismas que afectan el comportamiento de los secadores. Al integrar estos datos al modelo neuronal, este podría mejorar significativamente las aplicaciones y alcances del mismo. Para mejorar la base de datos, es necesario el refinamiento de los sistemas de adquisición de datos, especialmente el de peso, esto con el propósito de obtener datos de cinéticas de secado sin ruido en las lecturas o perturbaciones de las mismas.

Por otro lado, también es importante la integración del modelo neuronal en modelos de control ya establecidos, para mejorar el error de los controles tradicionales o en secadores donde no existe algún sistema de control. Con el objetivo de optimizar y automatizar el proceso de secado utilizando estrategias de aprendizaje y predicción.

6.2. Lista de publicaciones

- Diana Paola García-Moreira, Erick César López-Vidaña, Ivan Moreno, Dagoberto Rodríguez-Ortíz: “Optical characterization and thermal performance of a novel solar dryer with dynamic control of solar radiation” September 2024 Case Studies in Thermal Engineering DOI: 10.1016/j.csite.2024.105075

BIBLIOGRAFÍA

- [1] Maria Jose Gamez. *Objetivos y metas de desarrollo sostenible*. es. URL: <https://www.un.org/sustainabledevelopment/es/objetivos-de-desarrollo-sostenible/> (visitado 22-10-2024).
- [2] Maria Jose Gamez. *Objetivo 2: Poner fin al hambre*. es. URL: <https://www.un.org/sustainabledevelopment/es/hunger/> (visitado 22-10-2024).
- [3] UNEP. *El mundo desperdicia más de 1.000 millones de platos de comida al día*. es. URL: <https://www.unep.org/es/noticias-y-reportajes/comunicado-de-prensa/el-mundo-desperdicia-mas-de-1000-millones-de-platos-de> (visitado 27-03-2024).
- [4] FAO. *Pérdida y desperdicio de alimentos*. 2024. URL: [https://www.fao.org/policy-support/policy-themes/food-loss-food-waste/es/#:~:text=En%20todo%20el%20mundo%2C%20un,consumidores%20finales%20\(PNUMA%202021\) ..](https://www.fao.org/policy-support/policy-themes/food-loss-food-waste/es/#:~:text=En%20todo%20el%20mundo%2C%20un,consumidores%20finales%20(PNUMA%202021) ..)
- [5] Meylin Gabriela Par Gramajo. «Aplicación de los métodos de conservación de alimentos». es. En: *Revista Ingeniería y Ciencia* 1.15 (sep. de 2019). ISSN: 2411-9296. URL: <http://www.revistasguatemala.usac.edu.gt/index.php/riyc/article/view/1009> (visitado 23-10-2024).
- [6] López Vidaña Erick César et al. «Thermal performance of a passive, mixed-type solar dryer for tomato slices (*Solanum lycopersicum*)». En: *Renewable Energy* 147 (mar. de 2020), págs. 845-855. ISSN: 18790682. DOI: [10.1016/j.renene.2019.09.018](https://doi.org/10.1016/j.renene.2019.09.018).
- [7] Alex Martynenko y Andreas Bück. *Intelligent control in drying*. 2018.
- [8] Katsuhiko Ogata. *Ingeniería de control moderna*. Pearson Educación, 2010. ISBN: 9788483226605.
- [9] N. Romero. *Inteligencia artificial y energías renovables*. Inf. téc. Flobers, 2023.

- [10] Pedro Fito et al. «Vacuum impregnation for development of new dehydrated products». En: *Journal of Food Engineering* 49.4 (2001). Drying, págs. 297-302. ISSN: 0260-8774. DOI: [https://doi.org/10.1016/S0260-8774\(00\)00226-0](https://doi.org/10.1016/S0260-8774(00)00226-0). URL: <https://www.sciencedirect.com/science/article/pii/S0260877400002260>.
- [11] Om Prakash y Anil Kumar. *Solar Drying Technology Concept, Design, Testing, Modeling, Economics, and Environment*. Springer, 2017. ISBN: 978-981-10-3832-7. DOI: <10.1007/978-981-10-3833-4>. URL: <http://www.springer.com/series/8059>.
- [12] Ibrahim Doymaz y Mehmet Pala. «The thin-layer drying characteristics of corn». En: *Journal of Food Engineering* 60.2 (2003), págs. 125-130. ISSN: 0260-8774. DOI: [https://doi.org/10.1016/S0260-8774\(03\)00025-6](https://doi.org/10.1016/S0260-8774(03)00025-6). URL: <https://www.sciencedirect.com/science/article/pii/S0260877403000256>.
- [13] Erick César López Vidaña. «Caracterización y evaluación de la eficiencia térmica y de secado en un deshidratador híbrido (solar - gas)». Es. Tesis doct. Santa Cruz Xoxocotlán, Oaxaca: Centro Interdisciplinario de Investigación para el Desarrollo Integral Regional, 2011. URL: http://literatura.ciidiroaxaca.ipn.mx/jspui/bitstream/LITER_CIIDIROAX/273/1/L%C3%B3pez%20Vida%C3%B1a%C1a%2C%20E.%20C..pdf.
- [14] Abuelnuor A.A. Abuelnuor et al. «A comprehensive review of solar dryers incorporated with phase change materials for enhanced drying efficiency». En: *Journal of Energy Storage* 72 (2023), pág. 108425. ISSN: 2352-152X. DOI: <https://doi.org/10.1016/j.est.2023.108425>. URL: <https://www.sciencedirect.com/science/article/pii/S2352152X23018224>.
- [15] Warren S. McCulloch y Walter Pitts. «(1943) Warren S. McCulloch and Walter Pitts, .^A logical calculus of the ideas immanent in nervous activity," Bulletin of Mathematical Biophysics 5: 115-133». En: *Neurocomputing, Volume 1: Foundations of Research*. The MIT Press, abr. de 1988. ISBN: 9780262267137. DOI: <10.7551/mitpress/4943.003.0004>. eprint: <https://direct.mit.edu/book/chapter-pdf/2299285/c010045\9780262267137.pdf>. URL: <https://doi.org/10.7551/mitpress/4943.003.0004>.
- [16] Barrera Arrestegui Luis. «Fundamentos históricos y filosóficos de la inteligencia artificial». En: *UCV-HACER* 1 (2012), pág. 7. ISSN: 2305-8552. URL: <https://www.redalyc.org/pdf/5217/521752338014.pdf>.
- [17] Morales D. Martín et al. «Entrenamiento de una red neuronal artificial para la predicción de la radiación solar». En: *II Congreso Argentino de Energías Sustentables*. 2018.
- [18] J.A. Hernández-Pérez et al. «Neural networks for the heat and mass transfer prediction during drying of cassava and mango». En: *Innovative Food Science & Emerging Technologies* 5.1 (2004), págs. 57-64. ISSN: 1466-8564. DOI: <https://doi.org/10.1016/>

- j.ifset.2003.10.004. URL: <https://www.sciencedirect.com/science/article/pii/S1466856403000675>.
- [19] luis Escobar R., julio Valdes H. y Santiago Zapata C. *Redes neuronales artificiales en predicción de series de tiempo. una aplicacion a la industria.* Inf. téc. Universidad tecnológica metropolitana santiago de chile, 2010.
- [20] P. Dufour. «Control Engineering in Drying Technology: Review and Trends». En: *Drying Technology* 24.7 (2006), págs. 889-904. DOI: [10.1080/07373930600734075](https://doi.org/10.1080/07373930600734075). eprint: <https://doi.org/10.1080/07373930600734075>. URL: <https://doi.org/10.1080/07373930600734075>.
- [21] Aysel Arslan y İlknur Alibaş. «Assessing the effects of different drying methods and minimal processing on the sustainability of the organic food quality». En: *Innovative Food Science & Emerging Technologies* 94 (2024), pág. 103681. ISSN: 1466-8564. DOI: <https://doi.org/10.1016/j.ifset.2024.103681>. URL: <https://www.sciencedirect.com/science/article/pii/S1466856424001206>.
- [22] Lisete Fernandes y Pedro B. Tavares. «A Review on Solar Drying Devices: Heat Transfer, Air Movement and Type of Chambers». En: *Solar* 4.1 (2024), págs. 15-42. ISSN: 2673-9941. DOI: [10.3390/solar4010002](https://doi.org/10.3390/solar4010002). URL: <https://www.mdpi.com/2673-9941/4/1/2>.
- [23] Michelle De Los Angeles Cárdenas Ibáñez y Vicente Peñaranda Idrovo. «Análisis comparativo de algoritmos de control pid, fuzzy y predictivo aplicado a sistemas seguidores de la posición del sol para la captación de energía solar usando paneles fotovoltaicos». spa. Tesis de mtría. Espol, 2018. URL: <http://www.dspace.espol.edu.ec/handle/123456789/46062> (visitado 18-10-2024).
- [24] P.L. de Vaal. *What is classical control and when is it better than artificial intelligence?* 2000.
- [25] Farhat Mahmood et al. «Data-driven robust model predictive control for greenhouse temperature control and energy utilisation assessment». En: *Applied Energy* 343 (ago. de 2023). ISSN: 03062619. DOI: [10.1016/j.apenergy.2023.121190](https://doi.org/10.1016/j.apenergy.2023.121190).
- [26] Farhat Mahmood et al. «Data-driven robust model predictive control for greenhouse temperature control and energy utilisation assessment». En: *Applied Energy* 343 (2023), pág. 121190. ISSN: 0306-2619. DOI: <https://doi.org/10.1016/j.apenergy.2023.121190>. URL: <https://www.sciencedirect.com/science/article/pii/S0306261923005548>.
- [27] Zehui Jia, Yanhong Liu y Hongwei Xiao. «Deep Learning Prediction of Moisture and Color Kinetics of Apple Slices by Long Short-Term Memory as Affected by Blanching and Hot-Air Drying Conditions». En: *Processes* 12.8 (2024). ISSN: 2227-9717. DOI: [10.3390/pr12081724](https://doi.org/10.3390/pr12081724). URL: <https://www.mdpi.com/2227-9717/12/8/1724>.

- [28] Sławomir Francik et al. «Modeling the Drying Process of Onion Slices Using Artificial Neural Networks». En: *Energies* 17.13 (2024). ISSN: 1996-1073. DOI: [10.3390/en17133199](https://doi.org/10.3390/en17133199). URL: <https://www.mdpi.com/1996-1073/17/13/3199>.
- [29] Muhammed Emin Topal, Birol Şahin y Serkan Vela. «Artificial Neural Network Modeling Techniques for Drying Kinetics of Citrus medica Fruit during the Freeze-Drying Process». En: *Processes* 12.7 (2024). ISSN: 2227-9717. DOI: [10.3390/pr12071362](https://doi.org/10.3390/pr12071362). URL: <https://www.mdpi.com/2227-9717/12/7/1362>.
- [30] Halil Nusret Bulus. «Adaptive Neuro-Fuzzy Inference System and Artificial Neural Network Models for Predicting Time-Dependent Moisture Levels in Hazelnut Shells (*Corylus avellana L.*) and Prina (*Oleae europaea L.*)». En: *Processes* 12.8 (2024). ISSN: 2227-9717. DOI: [10.3390/pr12081703](https://doi.org/10.3390/pr12081703). URL: <https://www.mdpi.com/2227-9717/12/8/1703>.
- [31] Food y Agriculture Organization of the United Nations. *Consumo de energía*. Inf. téc. Food y Agriculture Organization of the United Nations, 1983.
- [32] Mauricio R. Henríquez y Patricio A. Palma. «Control automático de condiciones ambientales en domótica usando redes neuronales artificiales». En: *Informacion Tecnologica* 22 (3 2011), págs. 125-139. ISSN: 07168756. DOI: [10.4067/S0718-07642011000300014](https://doi.org/10.4067/S0718-07642011000300014).
- [33] D. K. Salunkhe H. R. Bolin y Daryl Lund. «Food dehydration by solar energy». En: *C R C Critical Reviews in Food Science and Nutrition* 16.4 (1982). PMID: 7047079, págs. 327-354. DOI: [10.1080/10408398209527339](https://doi.org/10.1080/10408398209527339). eprint: <https://doi.org/10.1080/10408398209527339>. URL: <https://doi.org/10.1080/10408398209527339>.
- [34] Athira M. Mohan, Nader Meskin y Hasan Mehrjerdi. «A comprehensive review of the cyber-attacks and cyber-security on load frequency control of power systems». En: *Energies* 13 (15 ago. de 2020). ISSN: 19961073. DOI: [10.3390/en13153860](https://doi.org/10.3390/en13153860).
- [35] Naji Abdenouri et al. «Model identification and fuzzy control of the temperature inside an active hybrid solar indirect dryer». En: *Solar Energy* 231 (ene. de 2022), págs. 328-342. ISSN: 0038092X. DOI: [10.1016/j.solener.2021.11.026](https://doi.org/10.1016/j.solener.2021.11.026).
- [36] Tomás Norton y Da-Wen Sun. «CFD: An Innovative and Effective Design Tool for the Food Industry». En: Springer, 2010, págs. 45-68. DOI: [10.1007/978-1-4419-7475-4_3](https://doi.org/10.1007/978-1-4419-7475-4_3). URL: [http://link.springer.com/10.1007/978-1-4419-7475-4_3](https://link.springer.com/10.1007/978-1-4419-7475-4_3).
- [37] Getachew Mekuria Habtemariam et al. «Predicting and classification of software reliability using ensemble learning». En: *Journal of Integrated Science and Technology* 13.2 (2025). Cited by: 0. DOI: [10.62110/sciencein.jist.2025.v13.1026](https://doi.org/10.62110/sciencein.jist.2025.v13.1026). URL: <https://www.scopus.com/inward/record.uri?eid=2-s2.0-85203454720&doi=10.621102fsciencein.jist.2025.v13.1026&partnerID=40&md5=c209b8903b776fbf5fe3580014b3cb63>.

- [38] A. Manonmani et al. «Modelling and control of greenhouse system using neural networks». En: *Transactions of the Institute of Measurement and Control* 40 (3 feb. de 2018), págs. 918-929. ISSN: 14770369. DOI: [10.1177/0142331216670235](https://doi.org/10.1177/0142331216670235).
- [39] Salwa Chtioui y Ahmed Khouya. «Mathematical modeling and performance evaluations of a wood drying process using photovoltaic thermal and double-pass solar air collectors». En: *Applied Thermal Engineering* 255 (2024), pág. 123901. ISSN: 1359-4311. DOI: <https://doi.org/10.1016/j.applthermaleng.2024.123901>. URL: <https://www.sciencedirect.com/science/article/pii/S1359431124015692>.
- [40] Gastronomía Solar. *Deshidratador solar y secado solar de alimentos*. 2022.
- [41] S Janjai y B K Bala. «Solar Drying Technology». En: *Food Engineering Reviews* (2011). DOI: [10.1007/s12393-011-9044-6](https://doi.org/10.1007/s12393-011-9044-6).
- [42] S. Nabnean et al. «Experimental performance of a new design of solar dryer for drying osmotically dehydrated cherry tomatoes». En: *Renewable Energy* 94 (2016), págs. 147-156. ISSN: 0960-1481. DOI: <https://doi.org/10.1016/j.renene.2016.03.013>. URL: <https://www.sciencedirect.com/science/article/pii/S0960148116301975>.
- [43] Rajendra Patil y Rupesh Gawande. *A review on solar tunnel greenhouse drying system*. Abr. de 2016. DOI: [10.1016/j.rser.2015.11.057](https://doi.org/10.1016/j.rser.2015.11.057).
- [44] O V Ekechukwu y B Norton. *Review of solar-energy drying systems II: an overview of solar drying technology*. 1999.
- [45] Aissa Atia, Mohamed Teggar y Abdelghani Laouer. «Performance of various solar dryer types integrating latent heat storage for drying agricultural products: An up-to-date review». En: *Journal of Energy Storage* 102 (2024), pág. 114048. ISSN: 2352-152X. DOI: <https://doi.org/10.1016/j.est.2024.114048>. URL: <https://www.sciencedirect.com/science/article/pii/S2352152X2403634X>.
- [46] A. Fudholi et al. *Review of solar dryers for agricultural and marine products*. Ene. de 2010. DOI: [10.1016/j.rser.2009.07.032](https://doi.org/10.1016/j.rser.2009.07.032).
- [47] Georgeta Sofia Popescu. Florina Radu. Ariana B Velcov. Luminița Pîrvulescu. Antoane-la Cozma. Mihaela Maria Stănciugelu. Daniela-Florentina Marcu. Nicoleta G Hădărugă. «A review: Water and methods employed for moisture determination in food». En: *Journal of Agroalimentary Processes and Technologies* (2022).
- [48] Shobhit Ambawat, Alka Sharma y Ramesh Kumar Saini. «Mathematical Modeling of Thin Layer Drying Kinetics and Moisture Diffusivity Study of Pretreated Moringa oleifera Leaves Using Fluidized Bed Dryer». En: *Processes* 10.11 (2022). ISSN: 2227-9717. DOI: [10.3390/pr10112464](https://doi.org/10.3390/pr10112464). URL: <https://www.mdpi.com/2227-9717/10/11/2464>.

- [49] Edgar Nelson Sánchez Camperos y Alma Yolanda Alanís García. *Redes neuronales Conceptos fundamentales y aplicaciones a control automático*. 1.^a ed. Pearson-prentice Hall, 2006, págs. 1-232. ISBN: 978-84-8322-295-9.
- [50] The MathWorks Inc. *¿Qué es una red neuronal?* 2024. URL: [The%20MathWorks,%20Inc..](#)
- [51] Simon S. Haykin y Simon S. Haykin. *Neural networks and learning machines*. Prentice Hall/Pearson, 2009, pág. 906. ISBN: 9780131471399.
- [52] David H Wolpert y William G Macready. *No Free Lunch Theorems for Optimization*. 1997.
- [53] George Philipp. *The nonlinearity coefficient - a practical guide to neural architecture design*. arXiv:2105.12210. Mayo de 2021. DOI: [10.48550/arXiv.2105.12210](#). URL: <http://arxiv.org/abs/2105.12210> (visitado 11-12-2024).
- [54] Stephen I.. Gallant. *Neural network learning and expert systems*. MIT Press, 1995, pág. 365. ISBN: 0262071452.
- [55] Fernando Berzal. *Redes neuronales y deep learning*. 2018.
- [56] Alma Y. Alanis, Nancy Arana-Daniel y Carlos López-Franco. *Bio-inspired Algorithms for Engineering*. 2018.
- [57] David Beasley, David R Bull y Ralph R Martin. *An Overview of Genetic Algorithms : Part 1, Fundamentals*. 1993.
- [58] J. Kennedy y R. Eberhart. «Particle swarm optimization». En: *Proceedings of ICNN'95 - International Conference on Neural Networks*. Vol. 4. IEEE, 1995, págs. 1942-1948. ISBN: 0-7803-2768-3. DOI: [10.1109/ICNN.1995.488968](#). URL: <http://ieeexplore.ieee.org/document/488968/>.
- [59] Dervis Karaboga. *An idea based on honey bee swarm for numerical optimization*. 2005.
- [60] Jagdish Chand Bansal, Harish Sharma y Shimpi Singh Jadon. *Artificial bee colony algorithm: a survey*. 2013.
- [61] España Castillo et al. «Diseño de Redes Neuronales Artificiales mediante algoritmos evolutivos Inteligencia Artificial». En: *Revista Iberoamericana de Inteligencia Artificial* 5 (14 2001), págs. 2-32. ISSN: 1137-3601. URL: <http://www.redalyc.org/articulo.oa?id=92551401>.
- [62] G. Thimm y E. Fiesler. «Neural network initialization». En: Springer, 1995, págs. 535-542. DOI: [10.1007/3-540-59497-3_220](#). URL: http://link.springer.com/10.1007/3-540-59497-3_220.
- [63] ICCSI. *Control inteligente: definición y beneficios*. 2024.

- [64] Wengang Hao et al. «Design and prediction method of dual working medium solar energy drying system». En: *Applied Thermal Engineering* 195 (ago. de 2021). ISSN: 13594311. DOI: [10.1016/j.applthermaleng.2021.117153](https://doi.org/10.1016/j.applthermaleng.2021.117153).
- [65] Hong Kuang. «Design of an Intelligent Instrument Communication System Based on RS485 Bus». En: *2024 International Conference on Integrated Circuits and Communication Systems (ICICACS)*. 2024, págs. 1-5. DOI: [10.1109/ICICACS60521.2024.10499077](https://doi.org/10.1109/ICICACS60521.2024.10499077).
- [66] Sensirion AG. *About us — Sensirion*. publisher: Sensirion AG. URL: <https://sensirion.com/company/about-sensirion>.
- [67] sensirion. *SHT4xI - Digital 4th Gen., High-Accuracy, 16-bit, Industrial Grad, Relative Humidity and Temperature Sensor*. Inf. téc. sensirion, 2023.
- [68] ht sensor technology co. , ltd. *Load cell manufacturer, strain gauge, pressure sensor supplier - ht sensor technology co. , ltd*. URL: <https://www.made-in-china.com/showroom/htechnology/>.
- [69] HT Sensor Technology CO. *TAL220 Parallel beam load cell*. Inf. téc. HT, 2023.
- [70] kipp & zonen. *History - kipp & zonen*. URL: <https://www.kippzonen.com/History>.
- [71] OTT HydroMet Corp. *CMP6 Pyranometer*. EN. (Visitado 2024).
- [72] Espressif Systems. *About espressif — espressif systems*. URL: <https://www.espressif.com/en/company/about-espressif>.
- [73] The MathWorks, Inc. *Patternnet*. publisher: MATLAB. URL: <https://la.mathworks.com/help/deeplearning/ref/patternnet.html>.
- [74] The MathWorks, Inc. *Feedforwardnet*. publisher: MATLAB. URL: <https://la.mathworks.com/help/deeplearning/ref/feedforwardnet.html>.
- [75] The MathWorks, Inc. *Cascadeforwardnet*. publisher: MATLAB. URL: <https://la.mathworks.com/help/deeplearning/ref/cascadeforwardnet.html>.
- [76] The MathWorks, Inc. *Fitnet*. publisher: MATLAB. URL: https://la.mathworks.com/help/deeplearning/ref/fitnet.html#bu2w2vc-1_seealso.
- [77] Halil Nusret Bulus. «Adaptive Neuro-Fuzzy Inference System and Artificial Neural Network Models for Predicting Time-Dependent Moisture Levels in Hazelnut Shells (*Corylus avellana L.*) and Prina (*Oleae europaea L.*)» En: *Processes* 12.8 (2024). ISSN: 2227-9717. DOI: [10.3390/pr12081703](https://doi.org/10.3390/pr12081703). URL: <https://www.mdpi.com/2227-9717/12/8/1703>.
- [78] Inc. The MathWorks. *Coeficiente de determinación (R cuadrado)*. EN. (Visitado 2024).

- [79] The MathWorks, Inc. *Acerca de MathWorks*. publisher: MATLAB. URL: <https://la.mathworks.com/company.html>.
- [80] Inc. The MathWorks. *Choose a Multilayer Neural Network Training Function*. EN. (Visitado 2024).
- [81] Jaime Pizarroso, José Portela y Antonio Muñoz. «NeuralSens: Sensitivity Analysis of Neural Networks». En: *Journal of Statistical Software* 102.7 (2022), págs. 1-36. DOI: [10.18637/jss.v102.i07](https://doi.org/10.18637/jss.v102.i07). URL: <https://www.jstatsoft.org/index.php/jss/article/view/v102i07>.